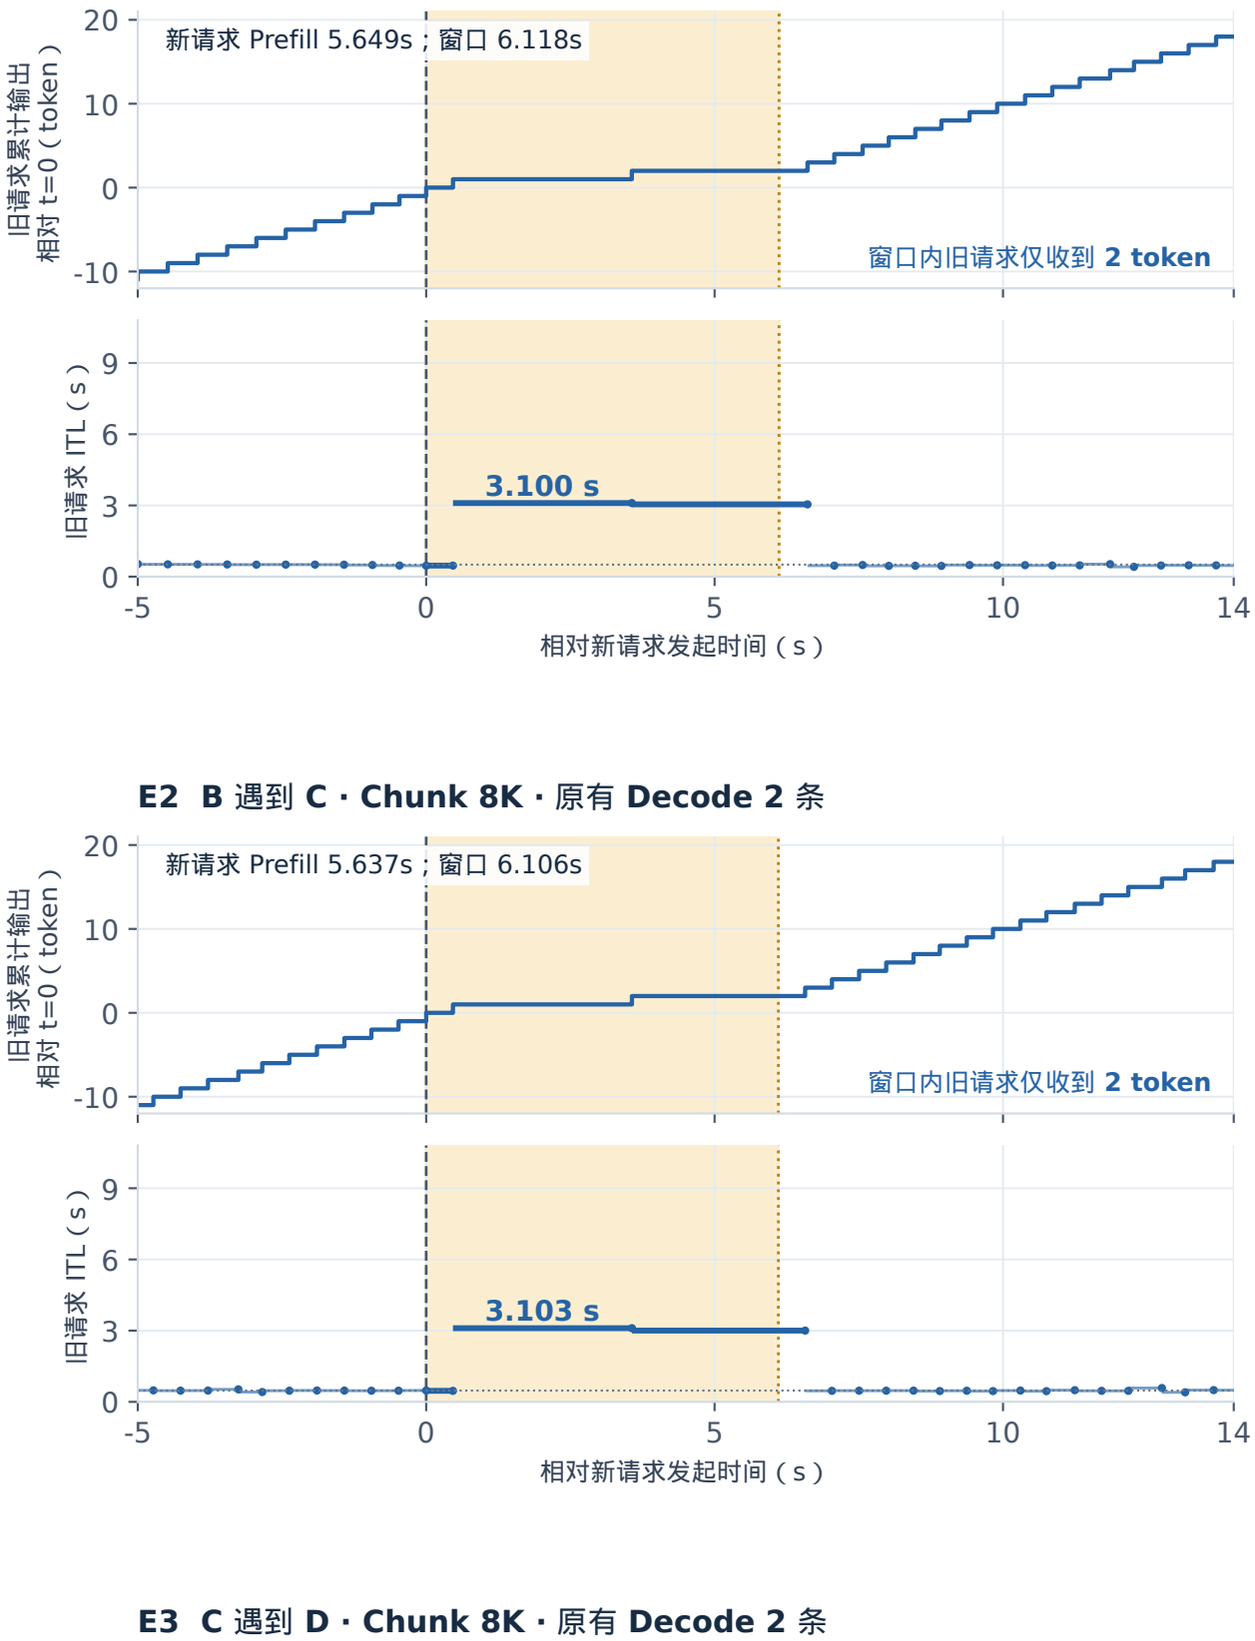
新 **Prefill** 到来时，已有 **Decode** 发生了什么？

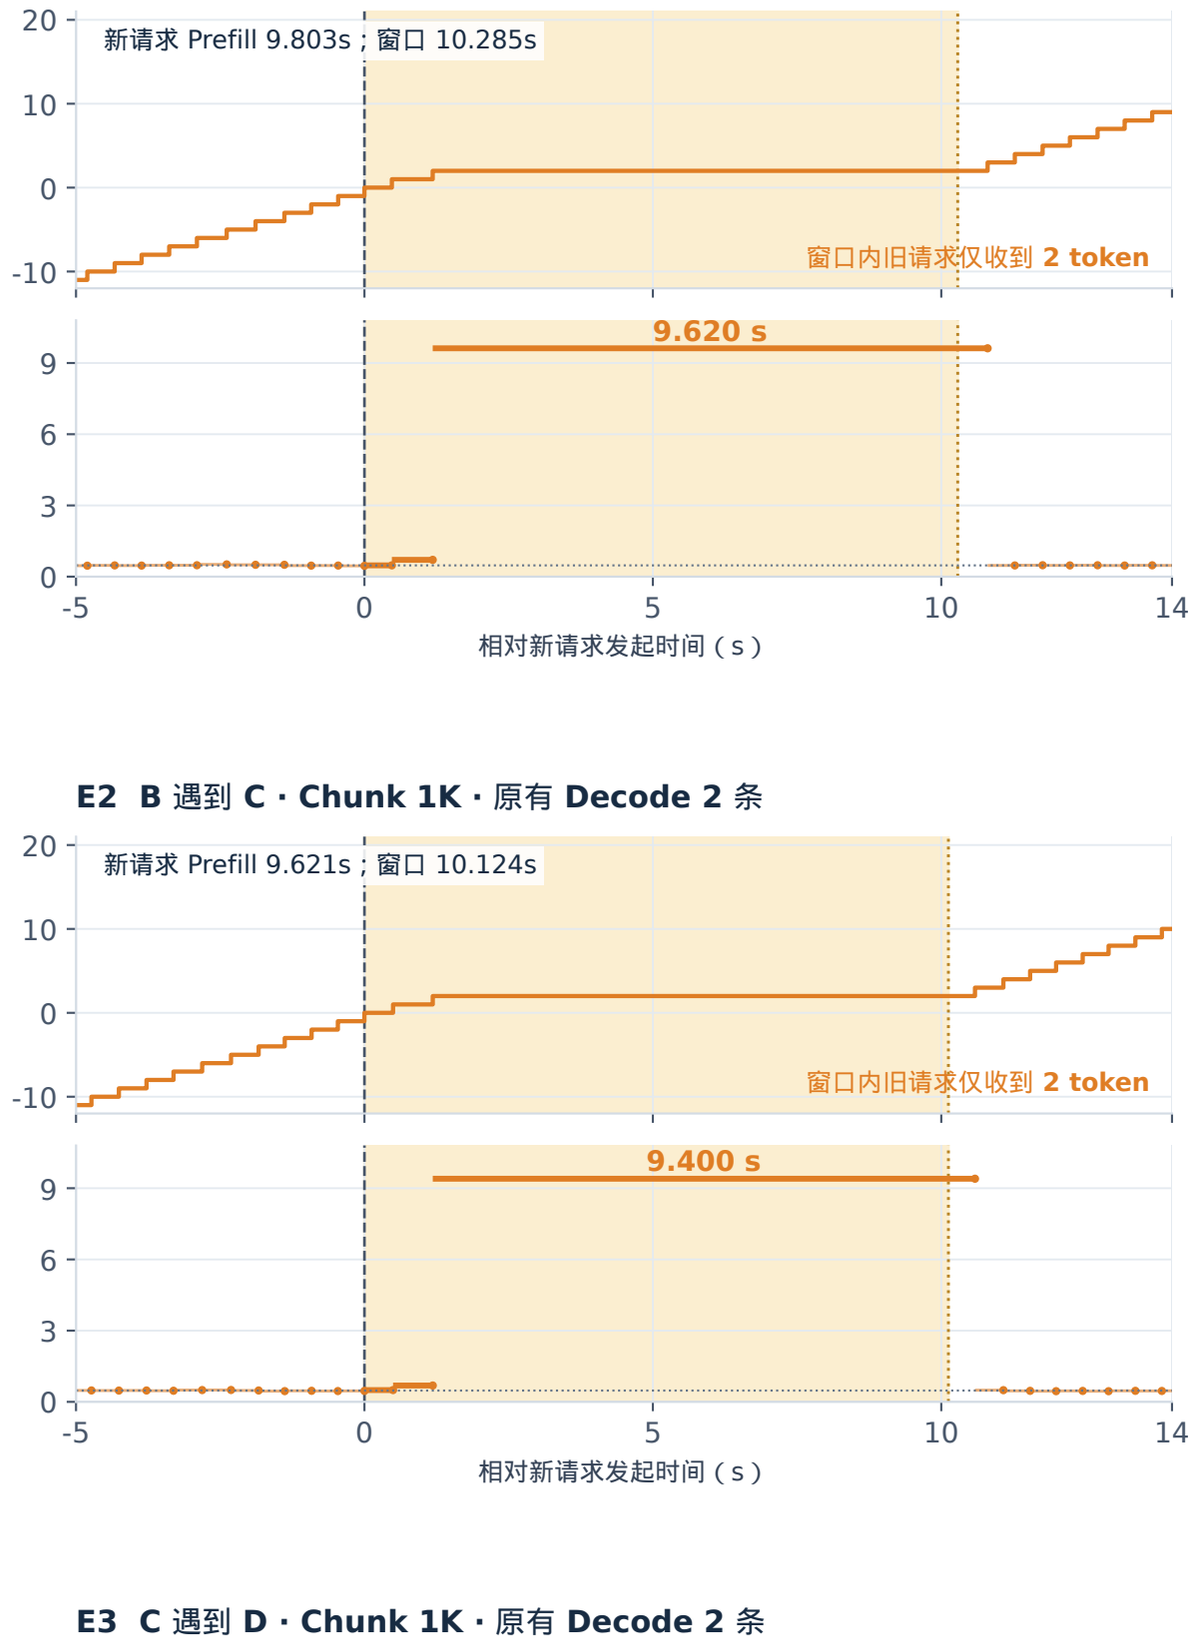
09-28 单轮数据 · 每档 4 请求 · 三次注入位置分别对齐 · 32K 输入 / 300 输出

新请求发起 → 新请求首 token（客户端窗口）　　发起时刻 t=0

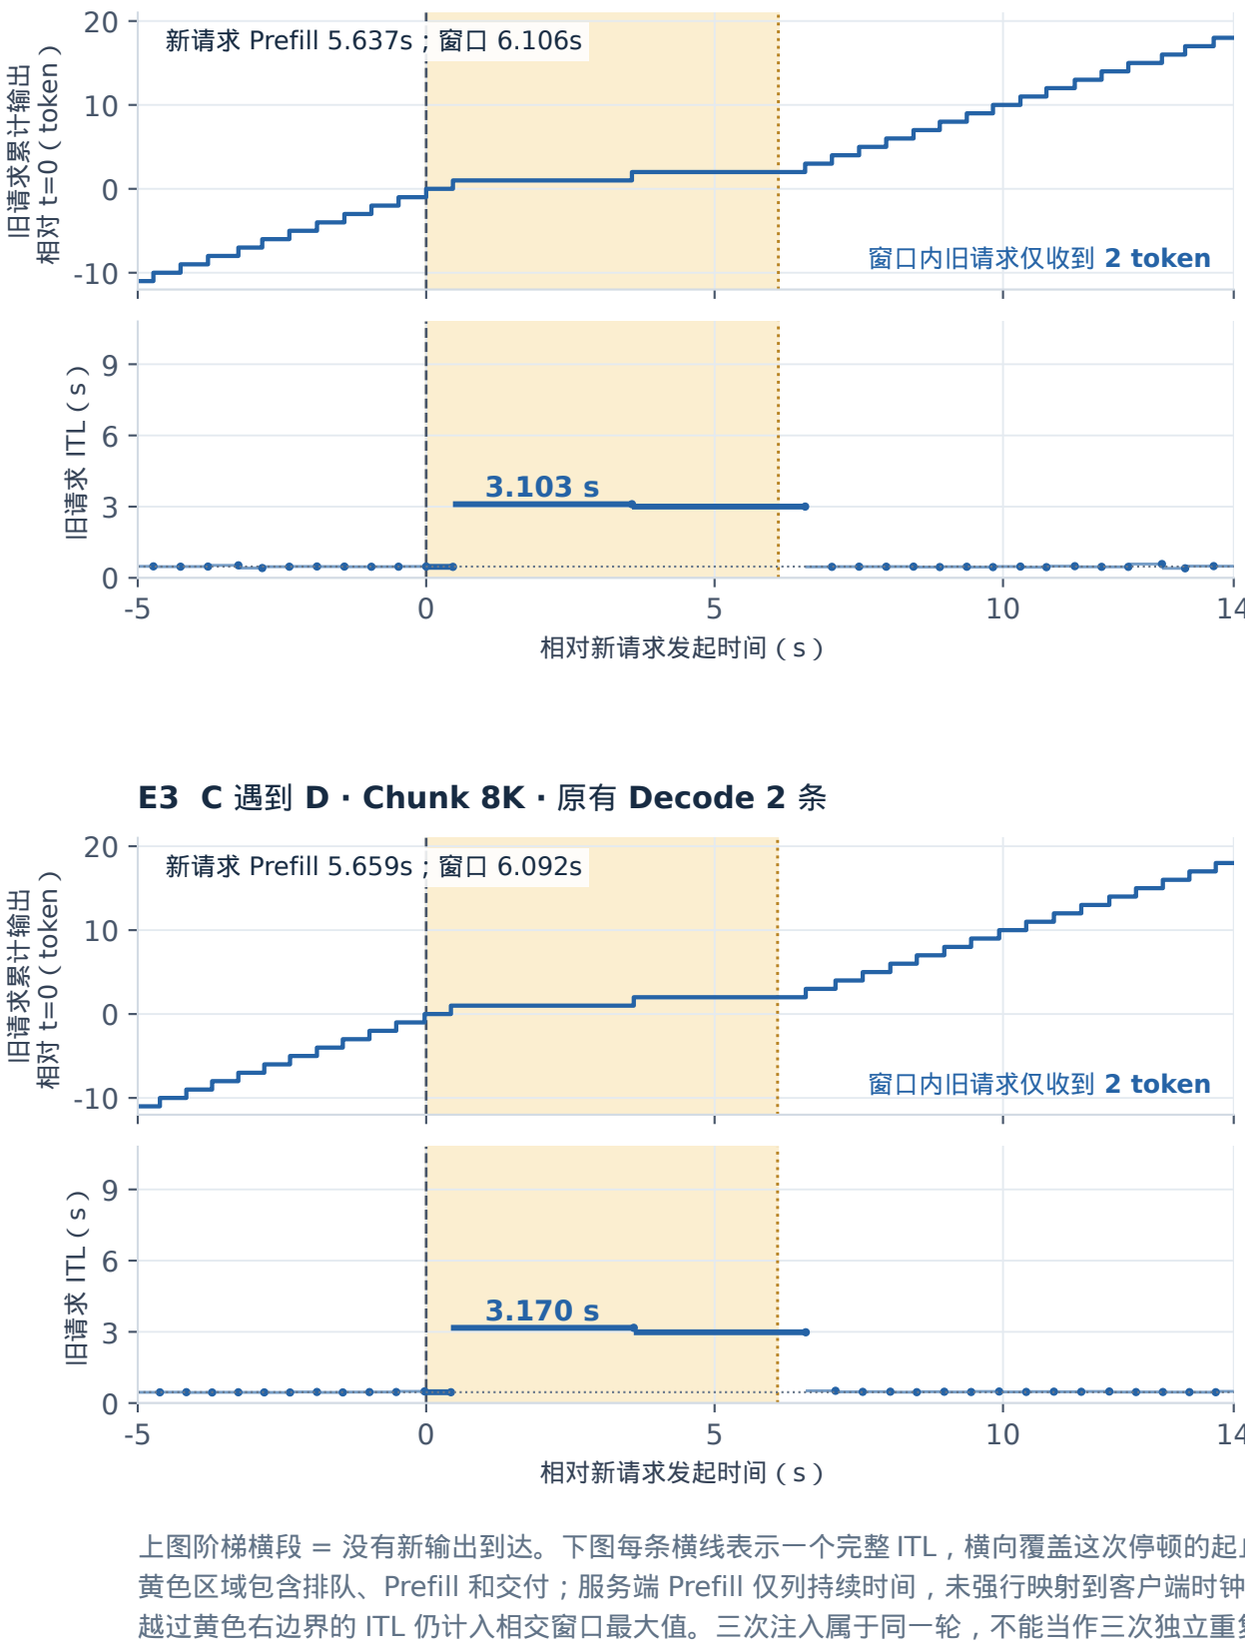
E1　A 遇到 B · Chunk 8K · 原有 Decode 1 条



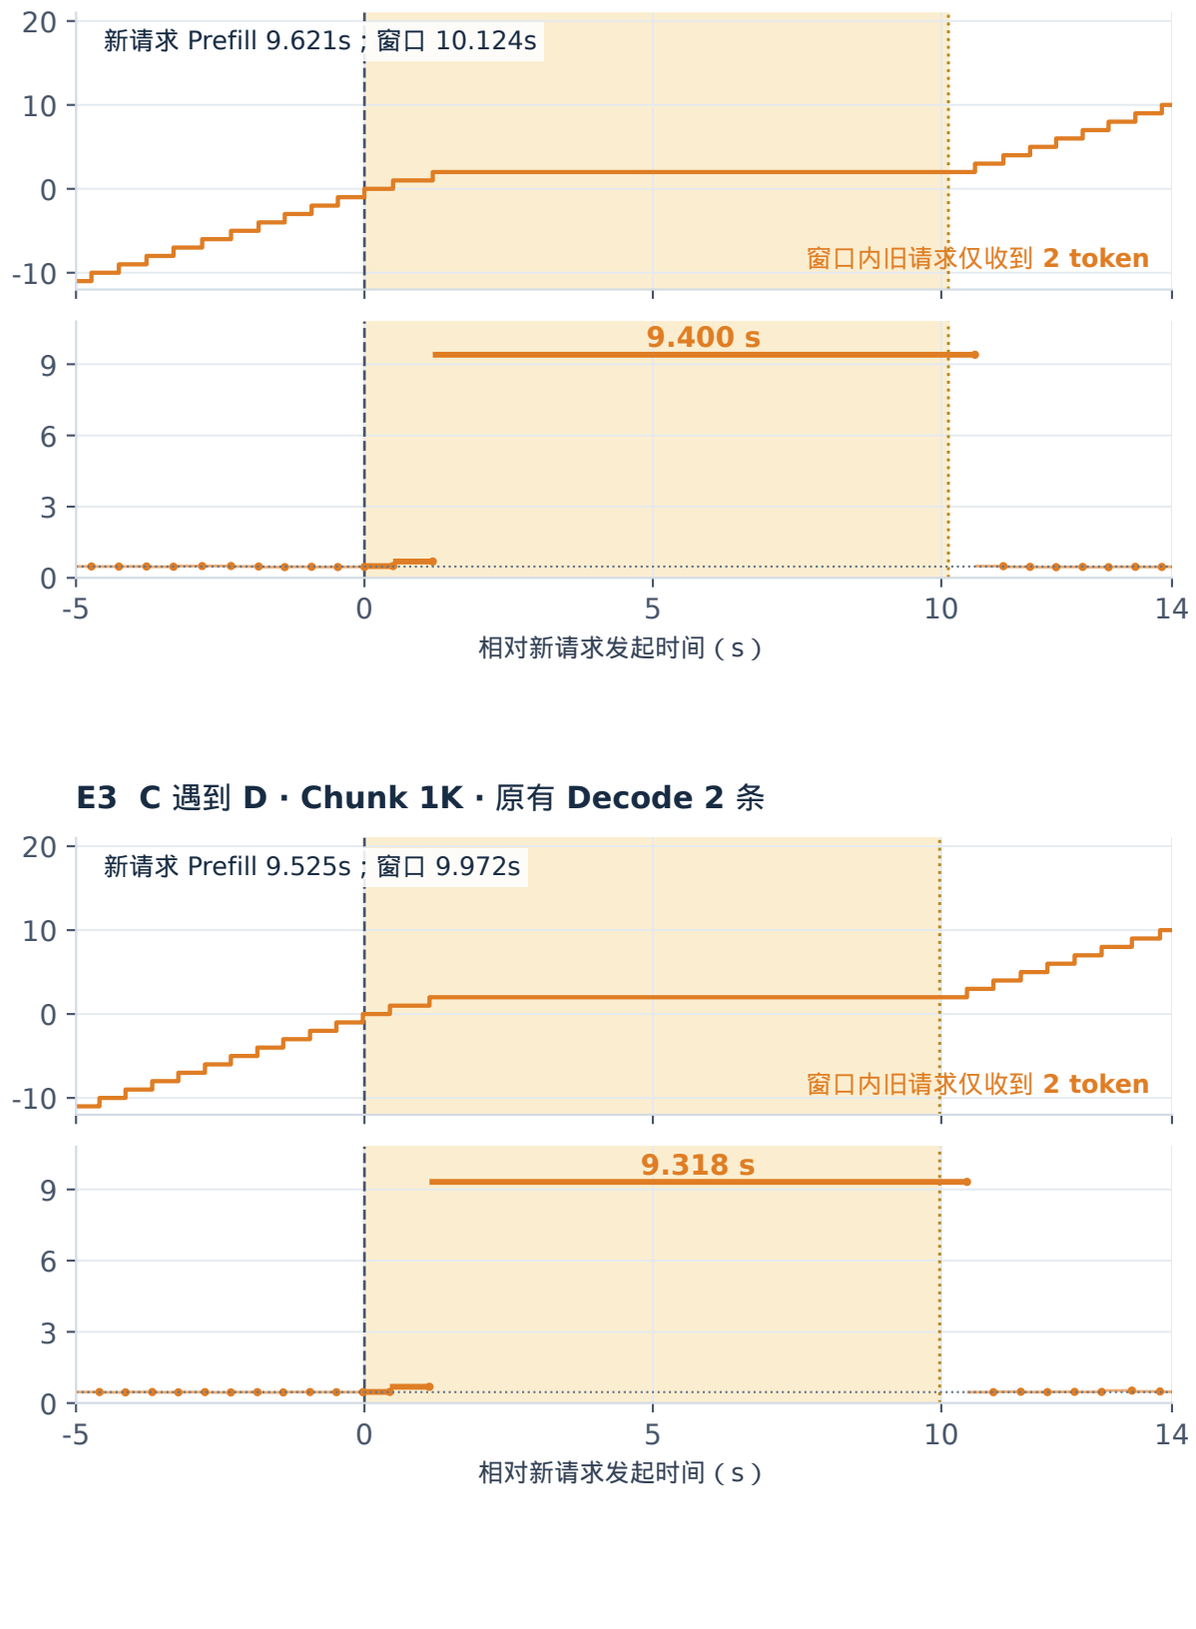
E1　A 遇到 B · Chunk 1K · 原有 Decode 1 条



E2　B 遇到 C · Chunk 8K · 原有 Decode 2 条



E2　B 遇到 C · Chunk 1K · 原有 Decode 2 条



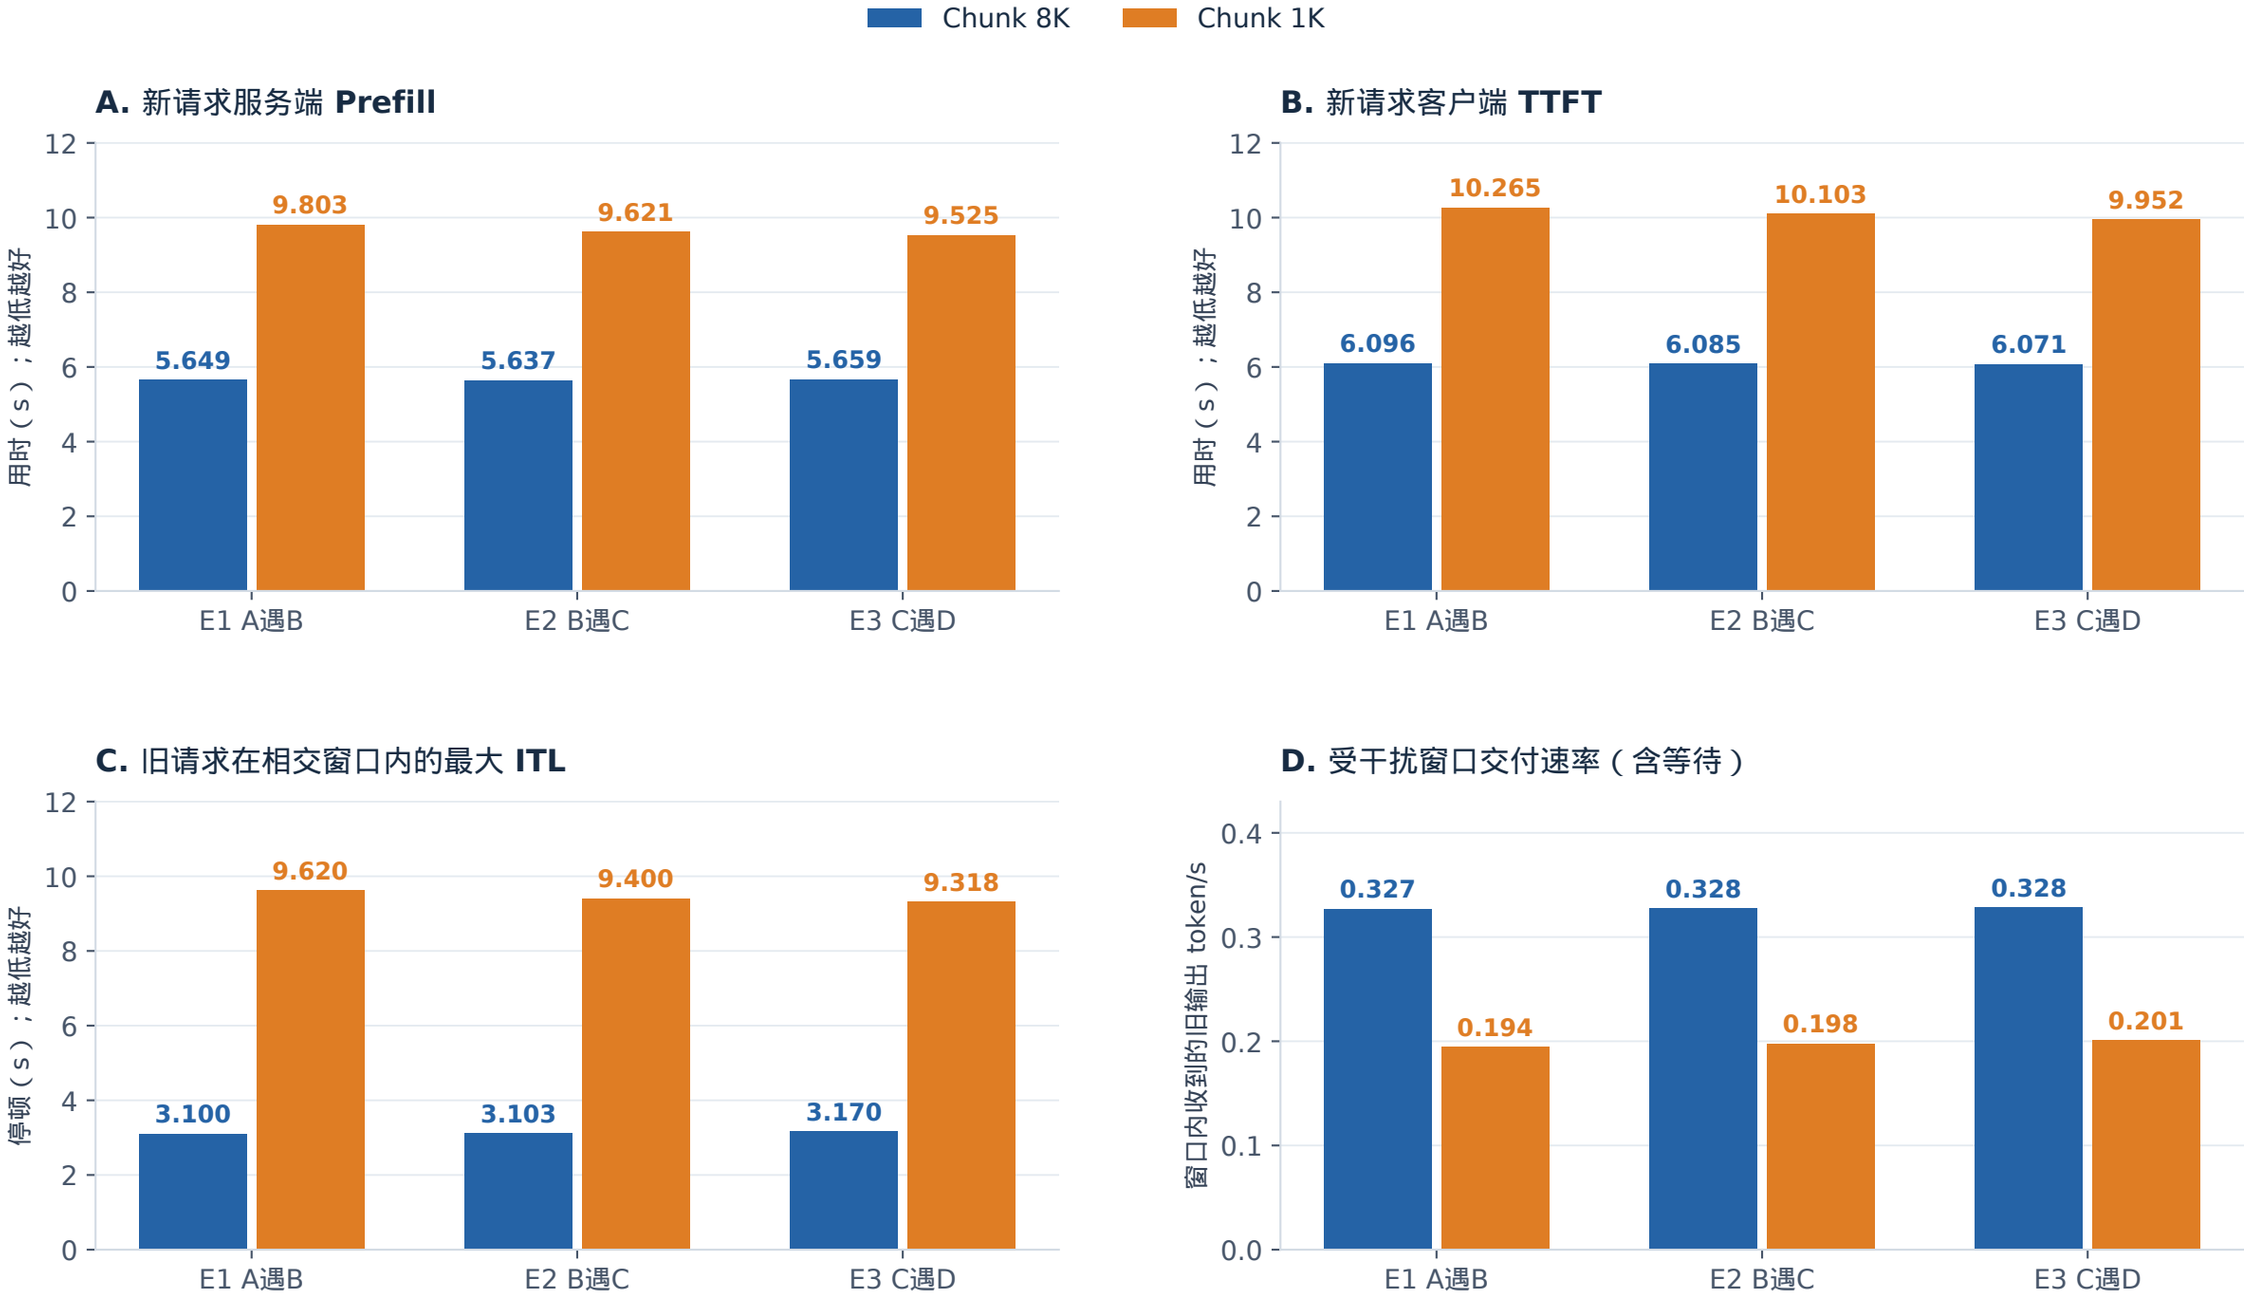
E3　C 遇到 D · Chunk 8K · 原有 Decode 2 条

E3　C 遇到 D · Chunk 1K · 原有 Decode 2 条

上图阶梯横段 = 没有新输出到达。下图每条横线表示一个完整 ITL，横向覆盖这次停顿的起止时间。
黄色区域包含排队、Prefill 和交付；服务端 Prefill 仅列持续时间，未强行映射到客户端时钟。
越过黄色右边界的 ITL 仍计入相交窗口最大值。三次注入属于同一轮，不能当作三次独立重复。

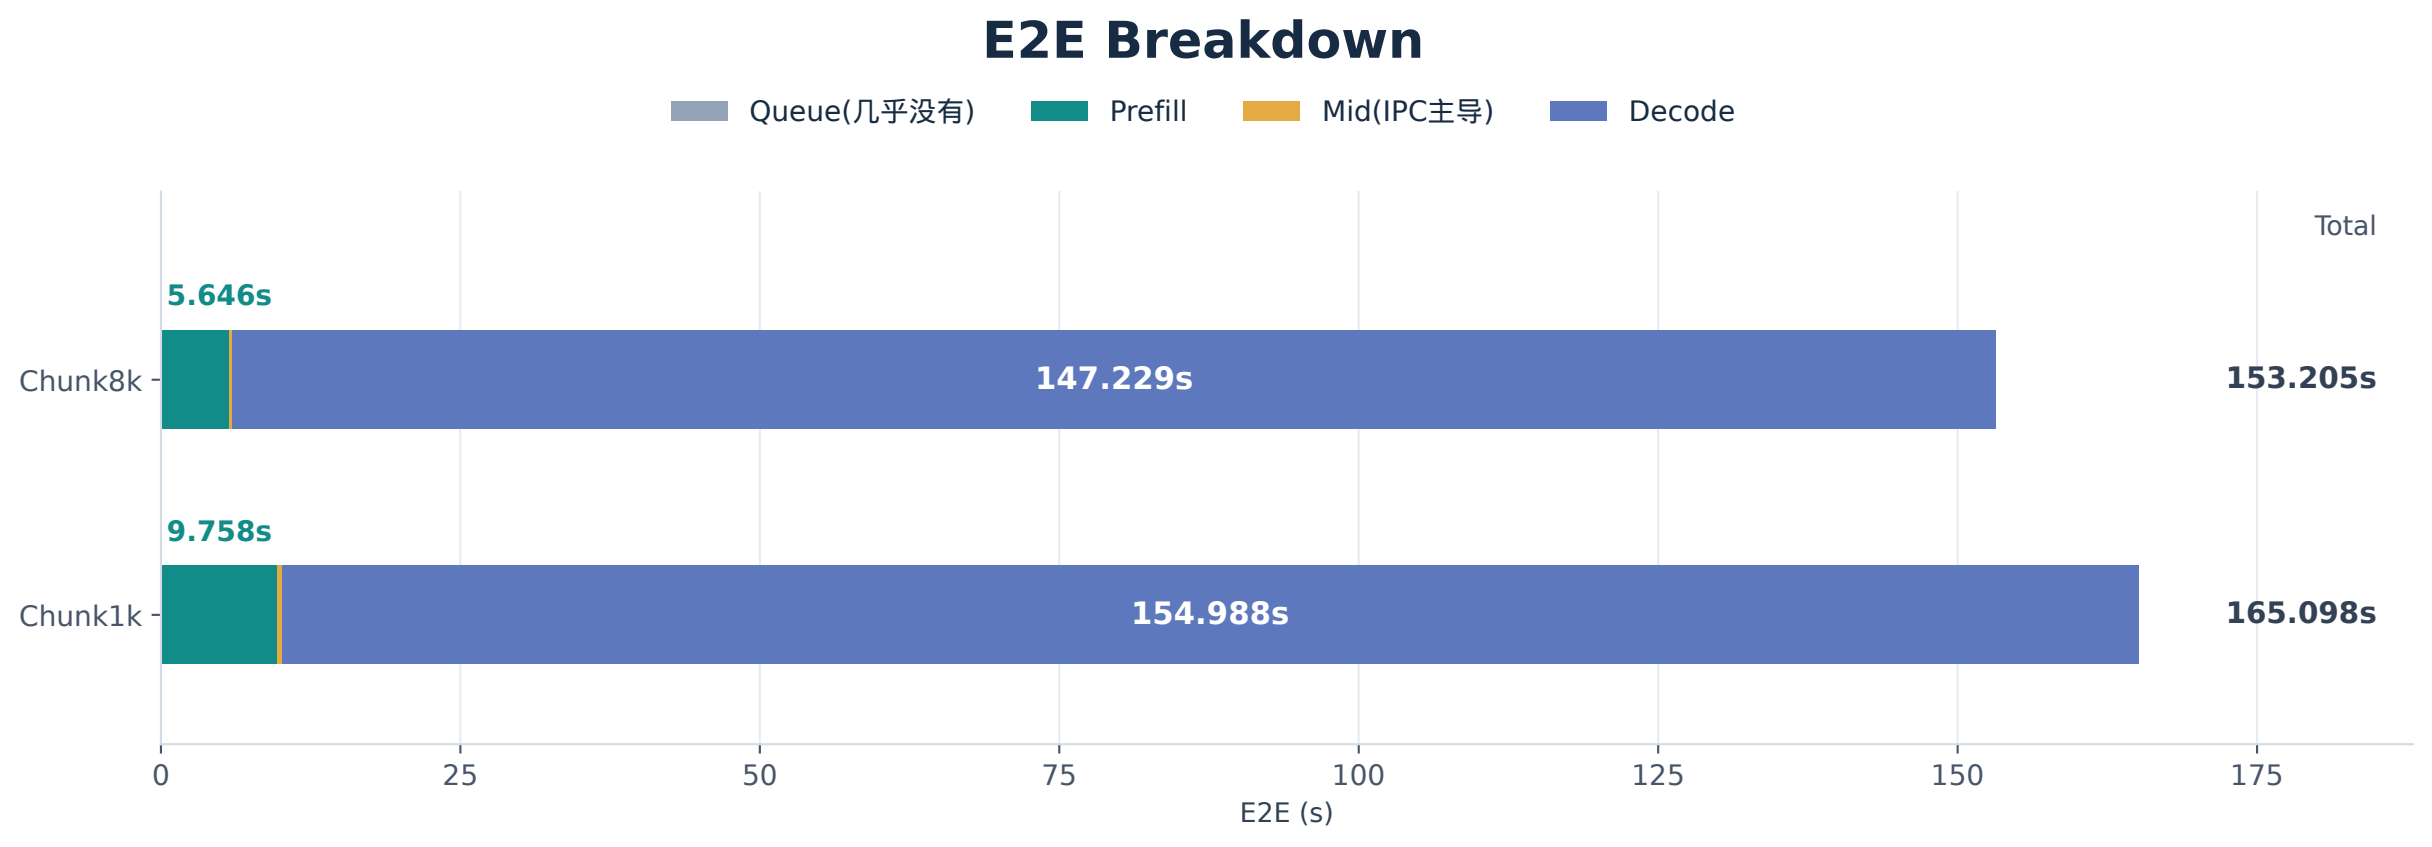
逐次注入：新请求延迟与旧请求停顿

每个柱子是一次注入观测；E1 原有 1 条 Decode，E2/E3 原有 2 条 Decode



窗口 = 新请求发起至其首 token；两档三个窗口中，观察的旧请求都恰好收到 2 token。

D 图的速率差由窗口时长不同产生，表示这段时间的交付体验，不能当作独立的 Decode 算子吞吐。


E2E Breakdown
Queue(几乎没有)
Prefill
Mid(IPC主导)
Decode
Total
5.646s
Chunk8k
147.229s
153.205s
9.758s
Chunk1k
154.988s
165.098s
0
25
50
75
100
125
150
175
E2E (s)

Prefill 处理速度，以及旧请求在注入期间的输出速度

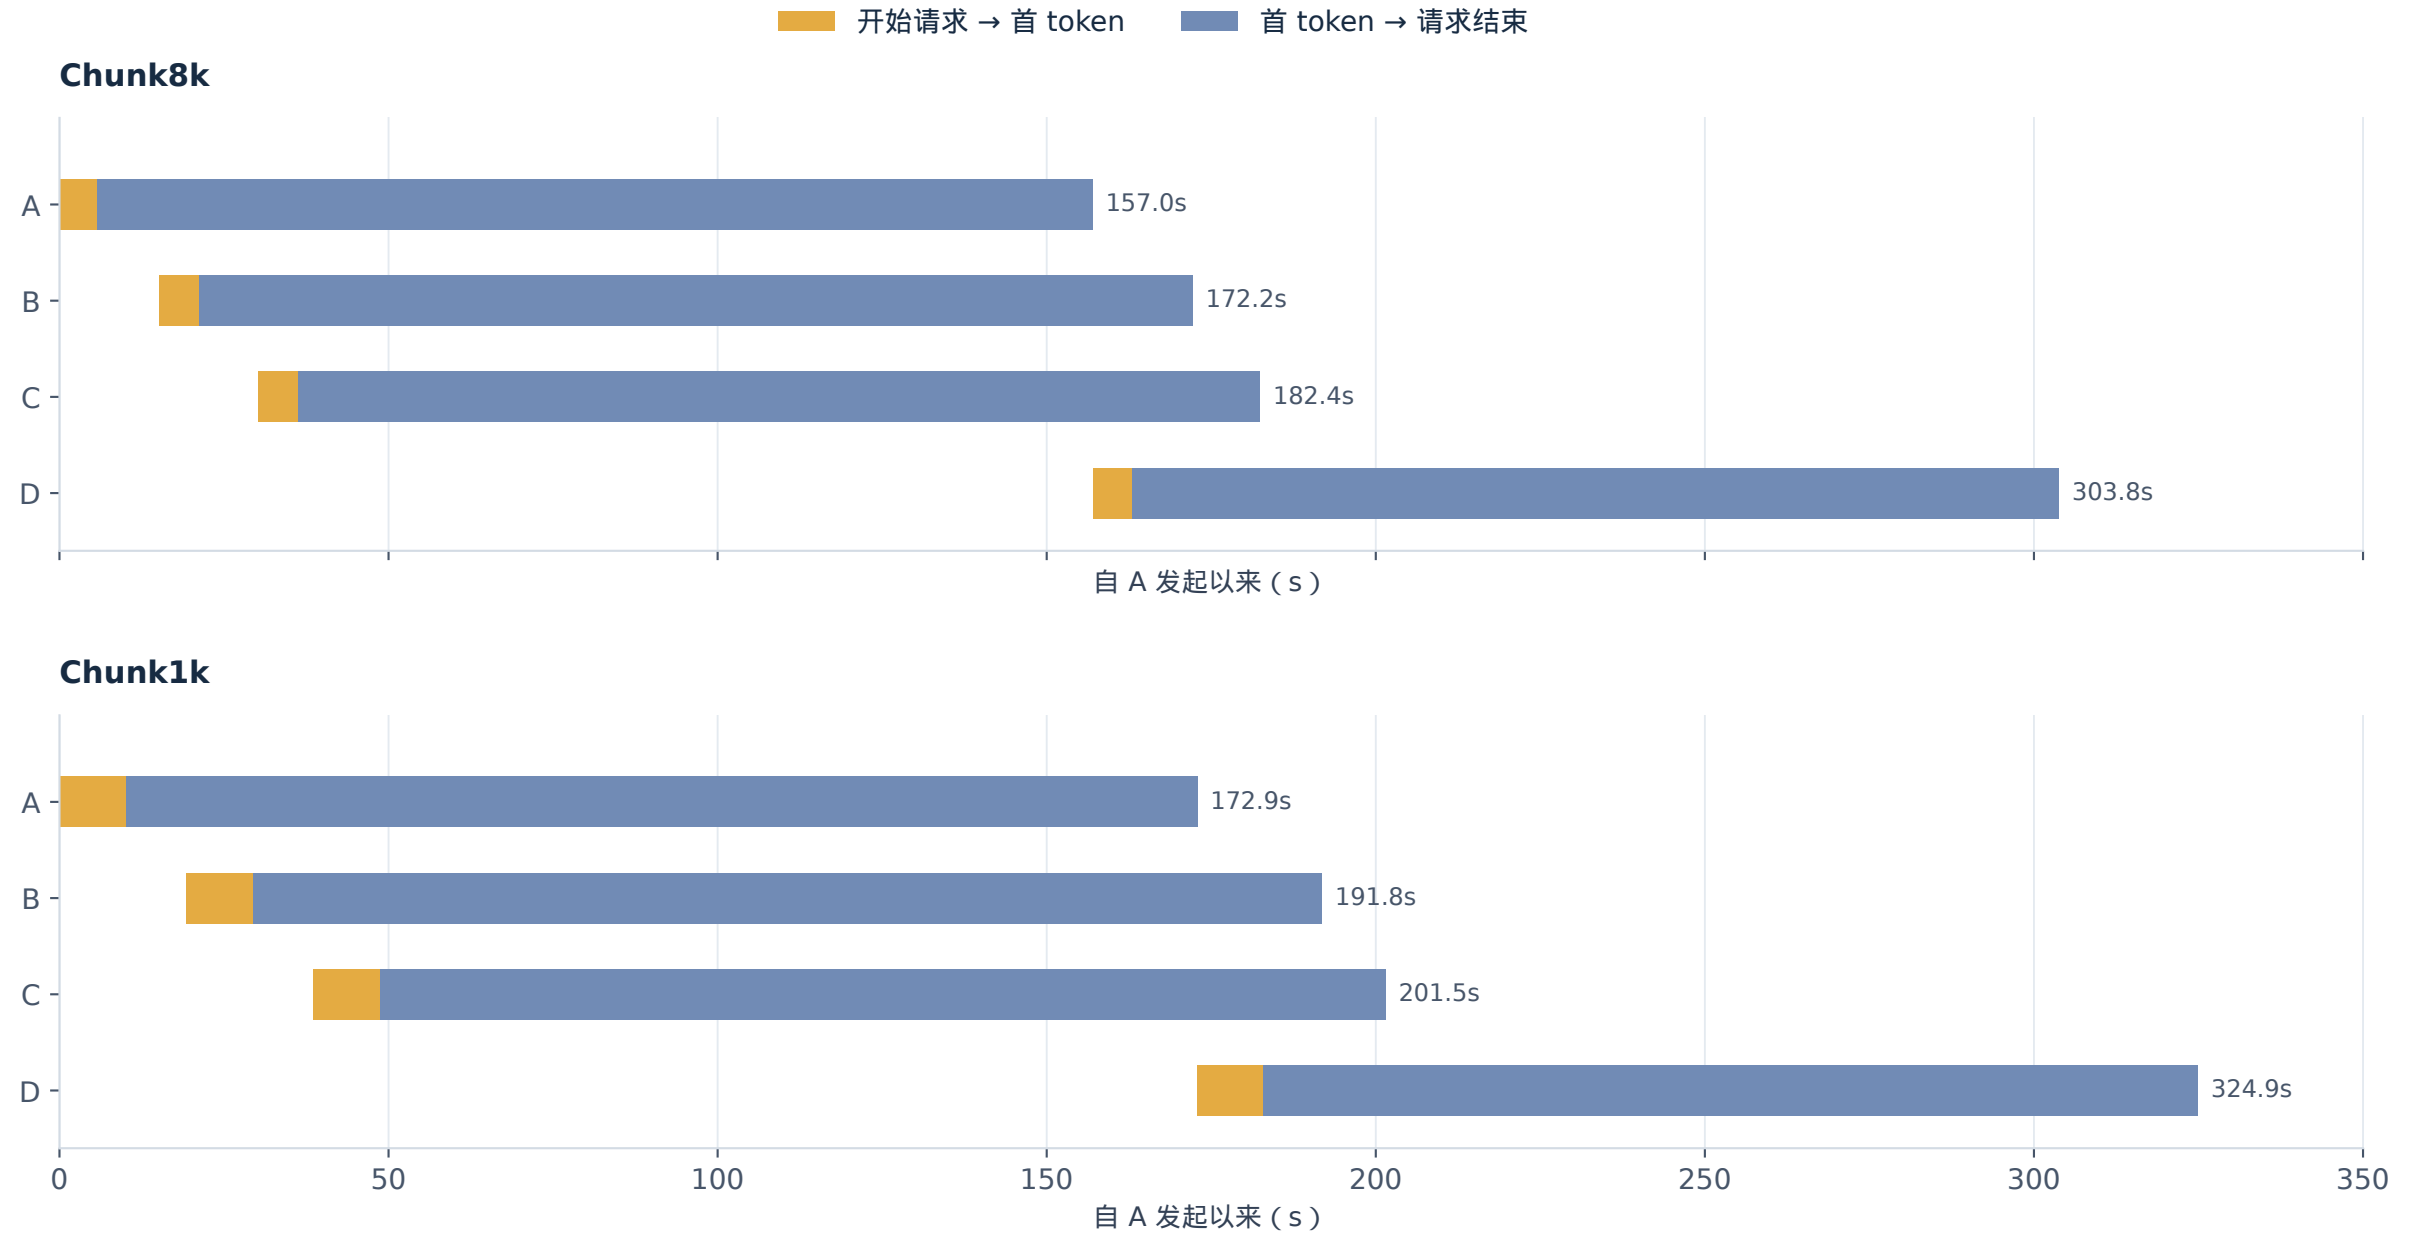
上：服务端 Prefill 阶段；下：客户端在指定窗口收到的输出



空心菱形 = 注入前最近至多 20 个完整 ITL 的平均速率（实际为 19/19/20 个间隔）。

它是同一请求的局部参考，不是另跑的无注入对照；柱子与菱形的观察窗口和统计方式不同。

四请求时序


开始请求 → 首 token
首 token → 请求结束
Chunk8k
A
B
C
D
157.0s
172.2s
182.4s
303.8s
自 A 发起以来（s）
Chunk1k
A
B
C
D
172.9s
191.8s
201.5s
324.9s
0
50
100
150
200
250
300
350
自 A 发起以来（s）