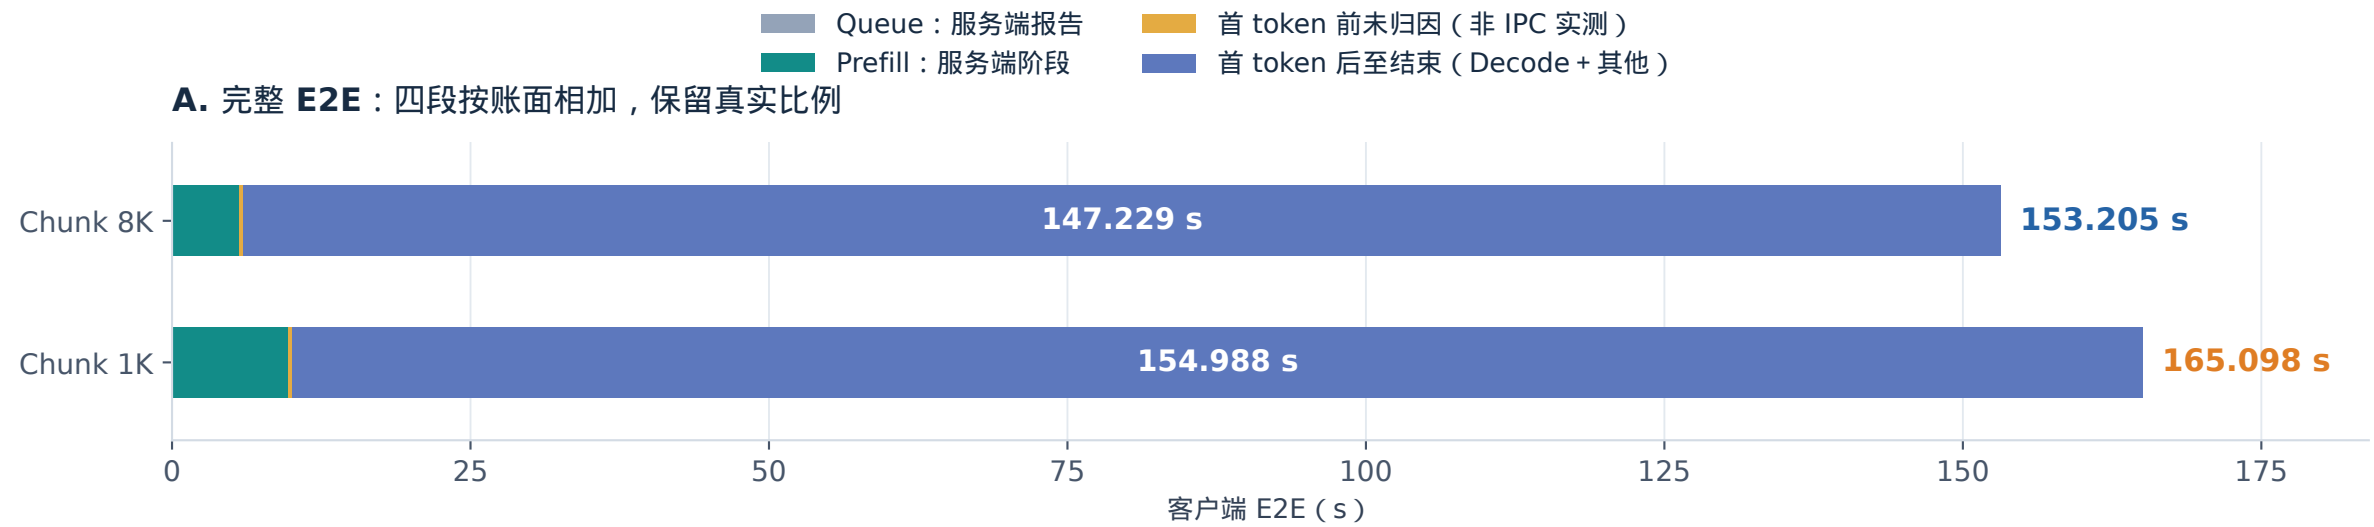
ChunkSize 8K / 1K：E2E 分解与 Prefill 放大

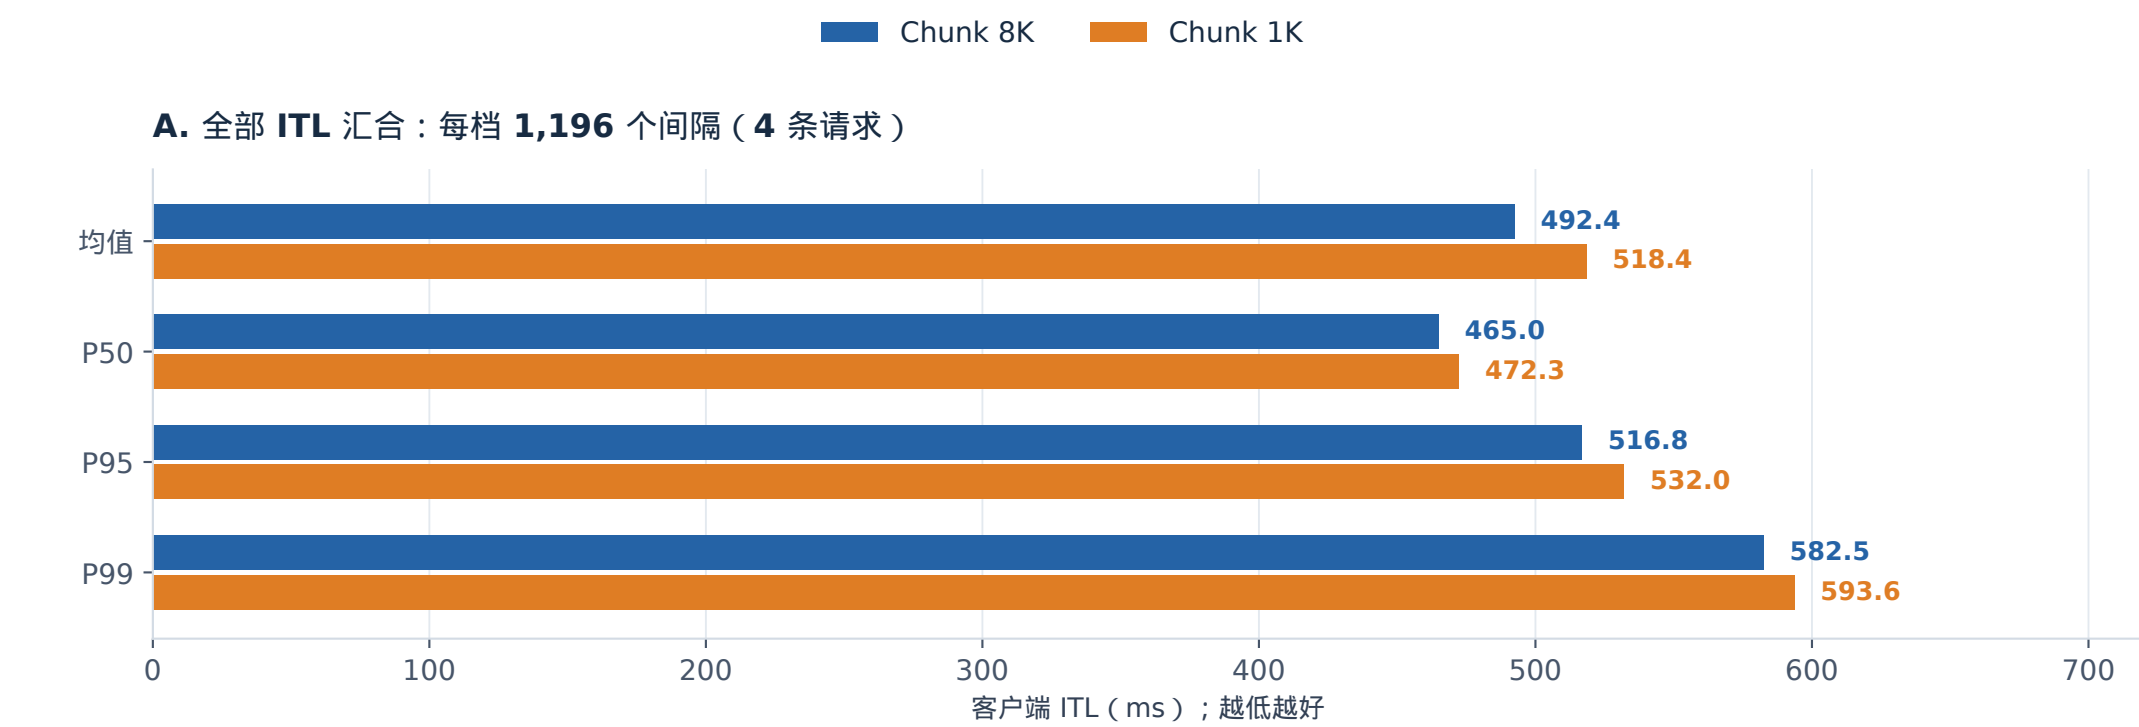
32K 总输入 · 19,584 token 命中 · 300 输出 · 每档 4 请求算术均值

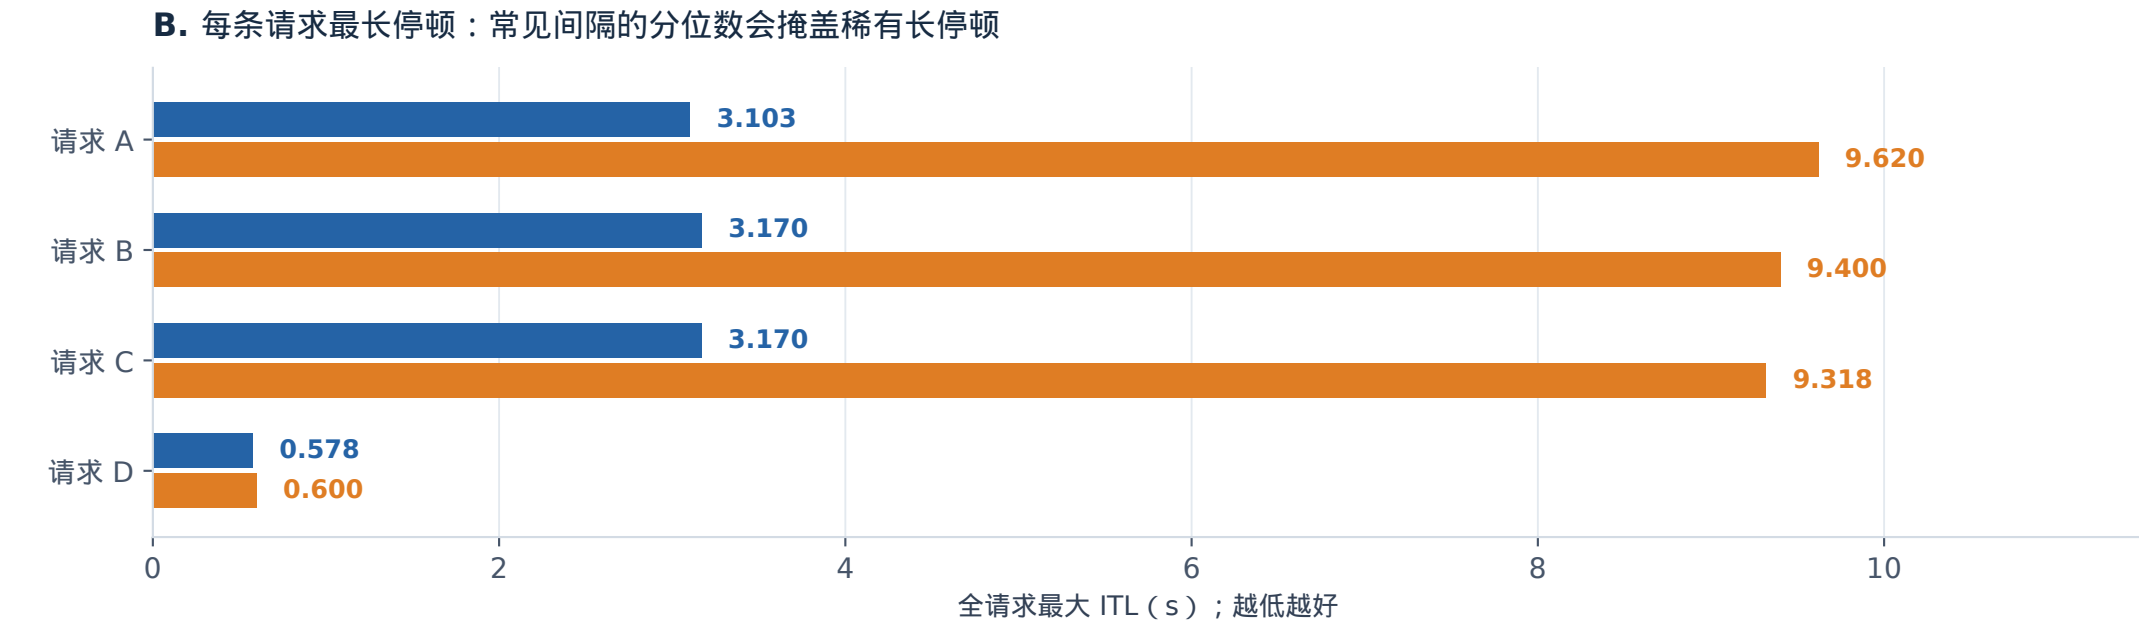


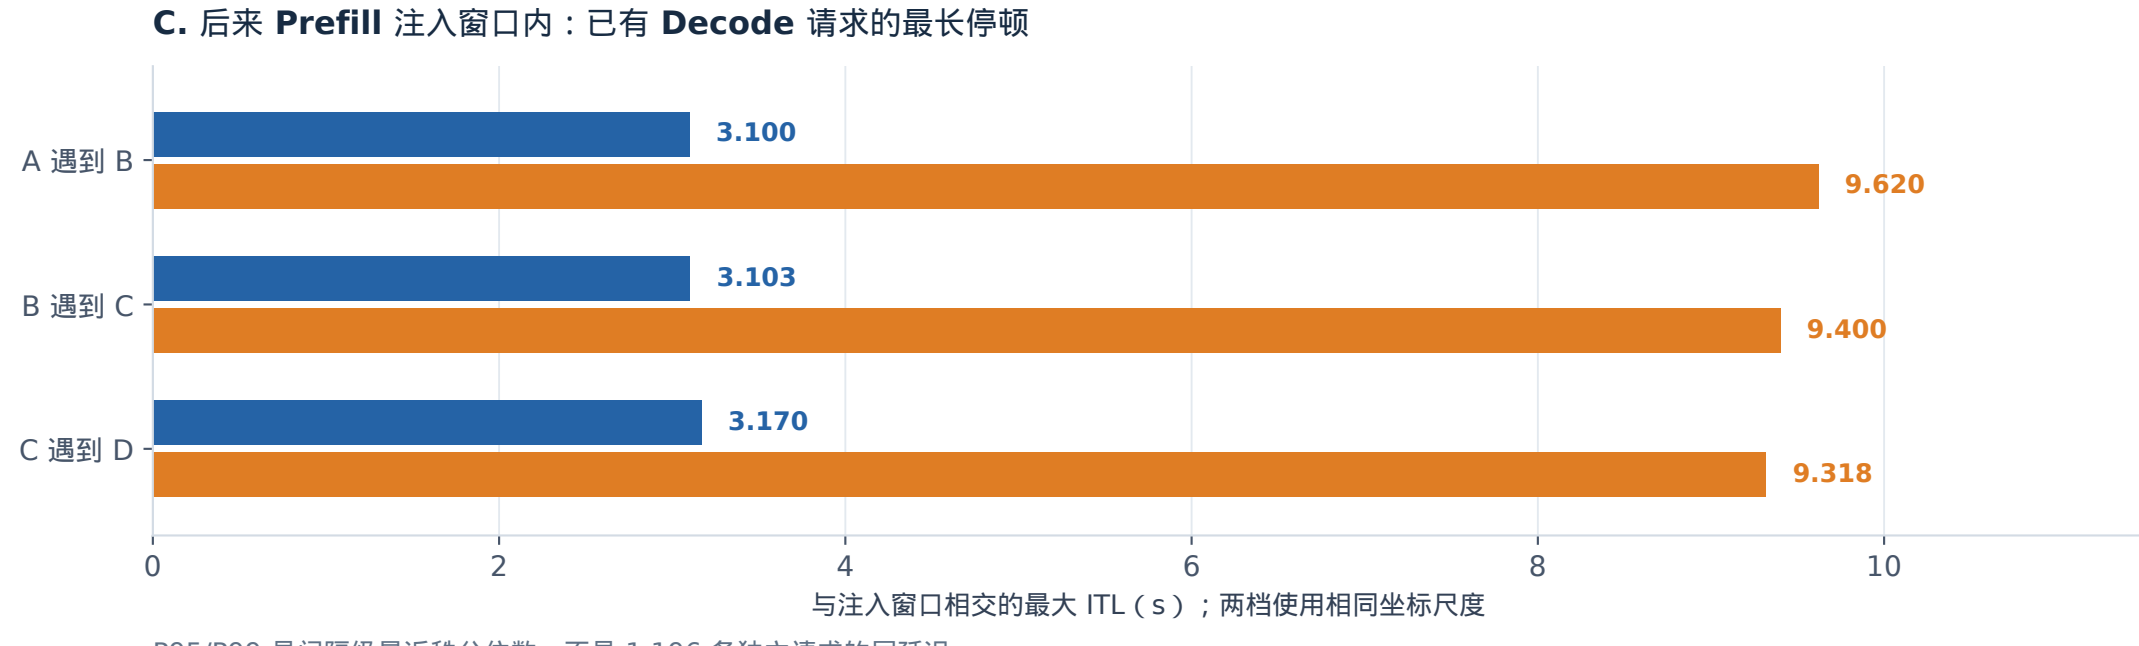
分解：Queue + Prefill + (TTFT − Queue − Prefill) + (E2E − TTFT)。
后两段含调度、传输及计时口径差等；这里不是 IPC / 纯 NPU Decode 的独立计时。

ChunkSize 8K / 1K：ITL 与长 Prefill 注入停顿

每条输出 300 token；每个 SSE 事件新增 1 token；ITL 为客户端到达间隔





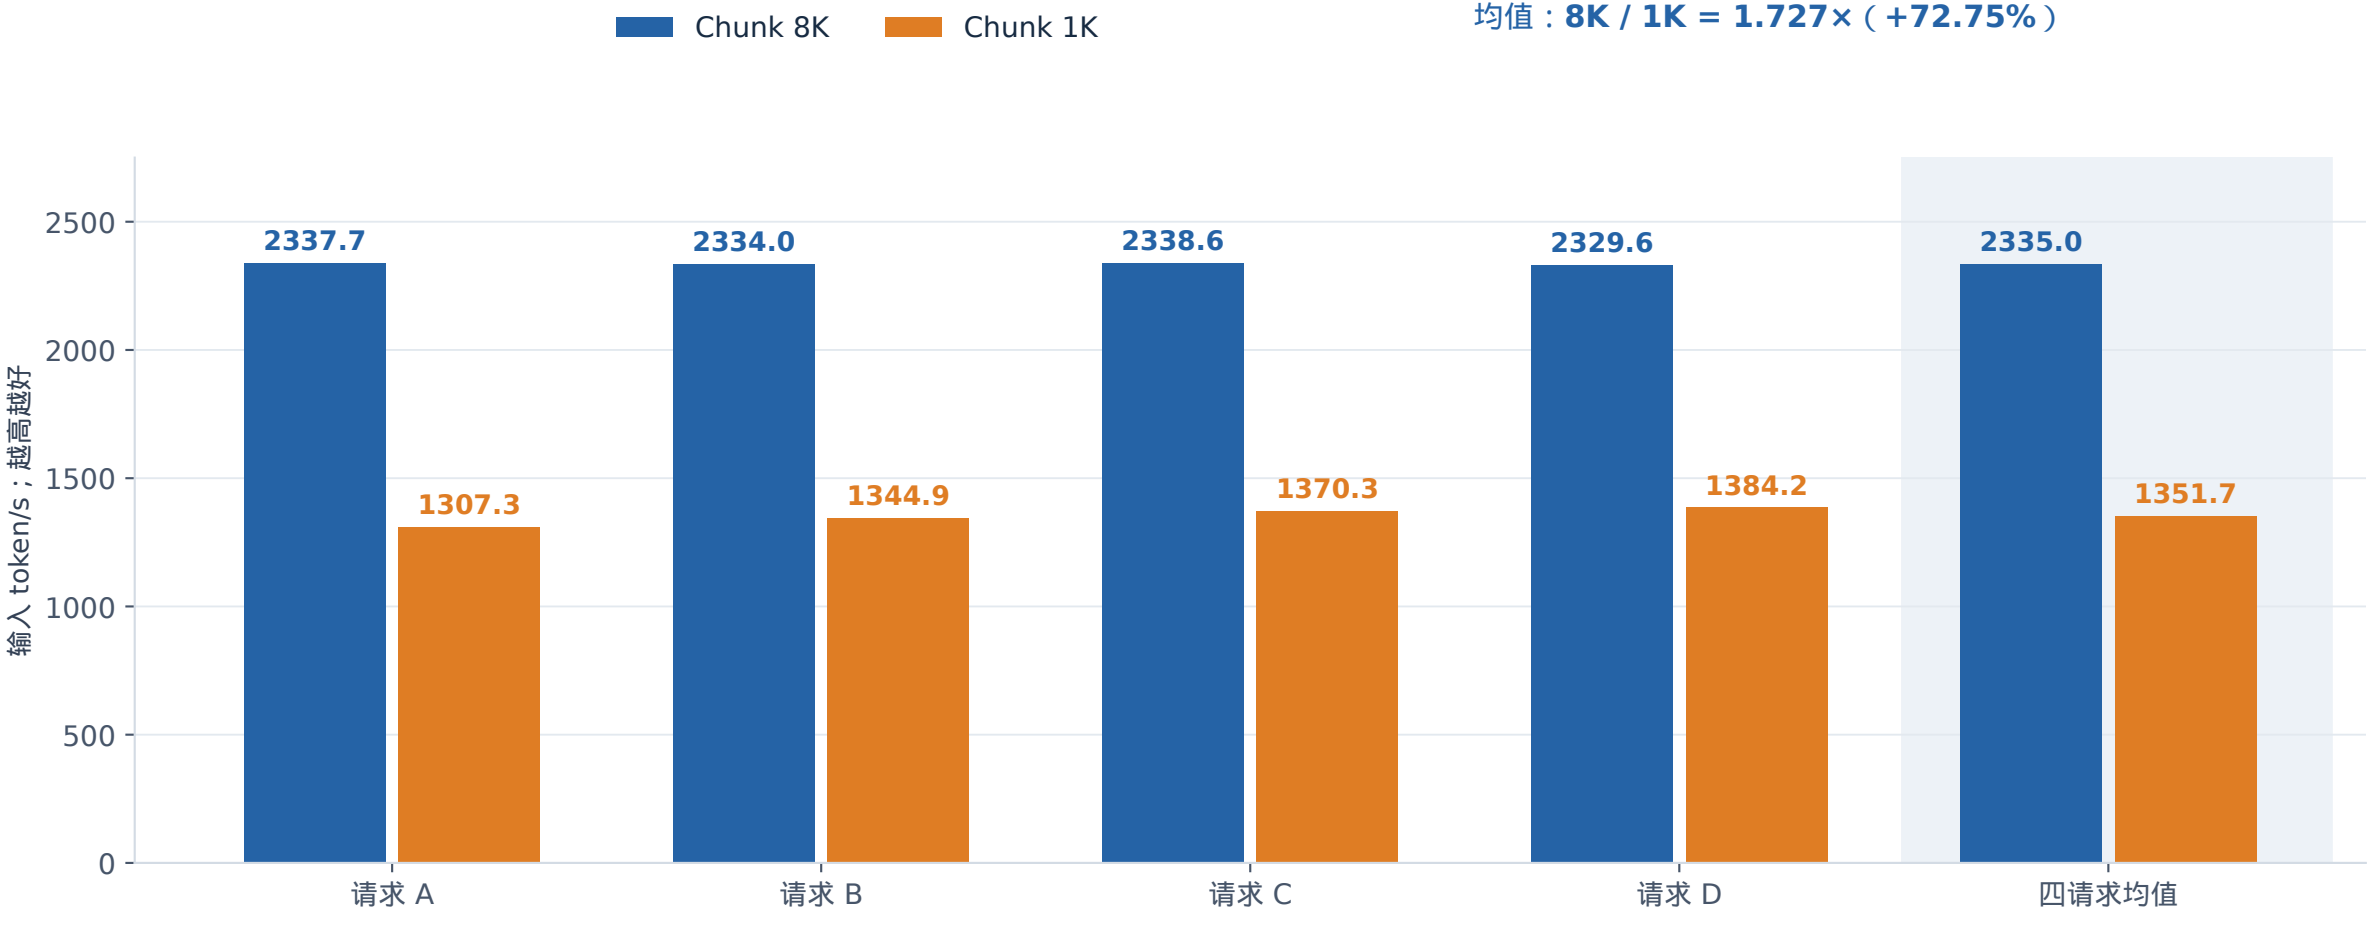


P95/P99 是间隔级最近秩分位数，不是 1,196 条独立请求的尾延迟。

注入窗口 = 后来请求发起至首 token 到达；包含排队、Prefill 和交付，不是纯 Prefill 区间。

ChunkSize 8K / 1K：Prefill 阶段处理速度

每条速度 = 13,184 个未命中输入 token / 服务端 Prefill 阶段时间

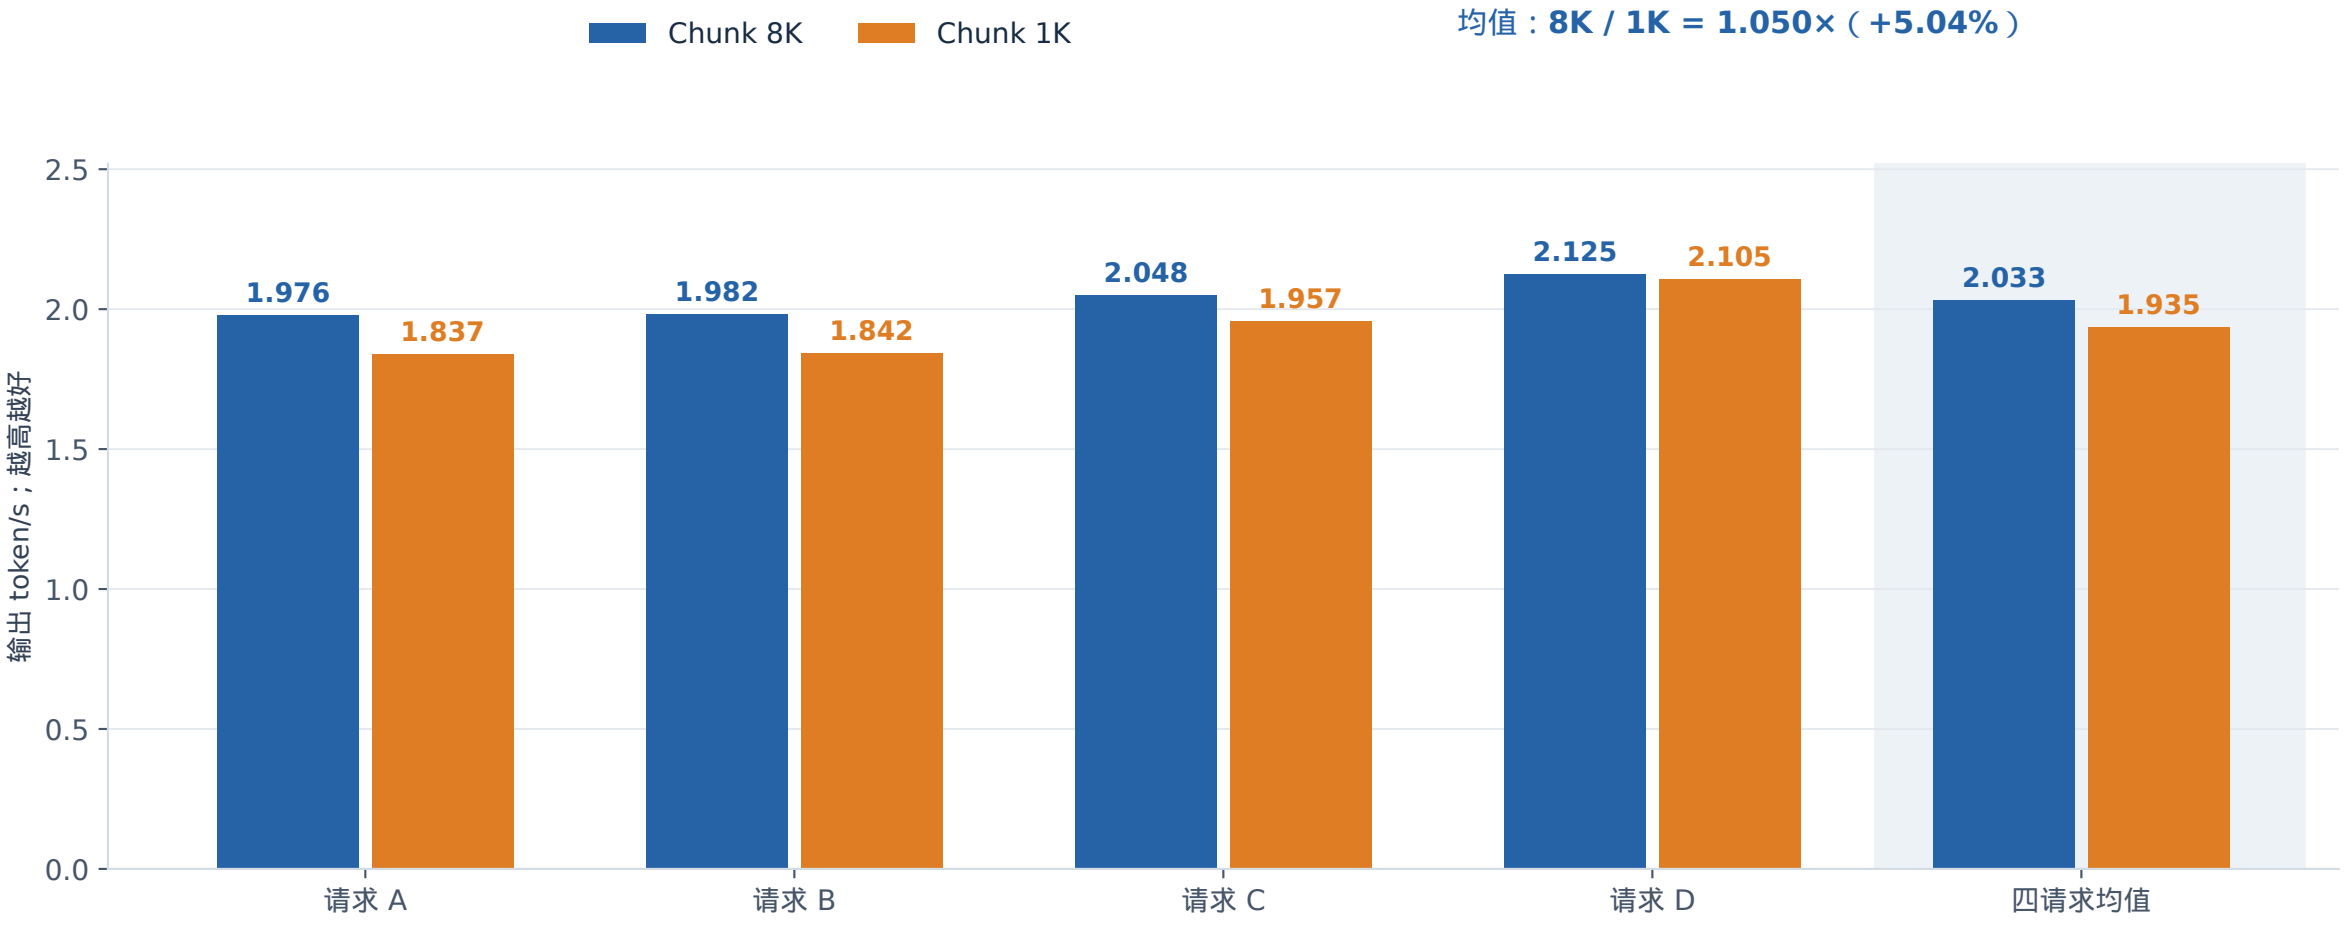


速度使用实际未命中输入量；缓存命中的 19,584 token 不进入分子。

服务端阶段区间可能包含调度等开销；不是纯 NPU 算子速度，也不是多请求服务总吞吐。

ChunkSize 8K / 1K：首 token 后平均输出速度

每条速度 = 299 个后续输出 token / (客户端 E2E − TTFT) = 1000 / TPOT(ms)



首 token 后时间包含其他请求 Prefill 造成的等待、生成、传输和结束收尾。

本轮为错开到达的混合负载；此图不能解释为纯 Decode 内核提速。