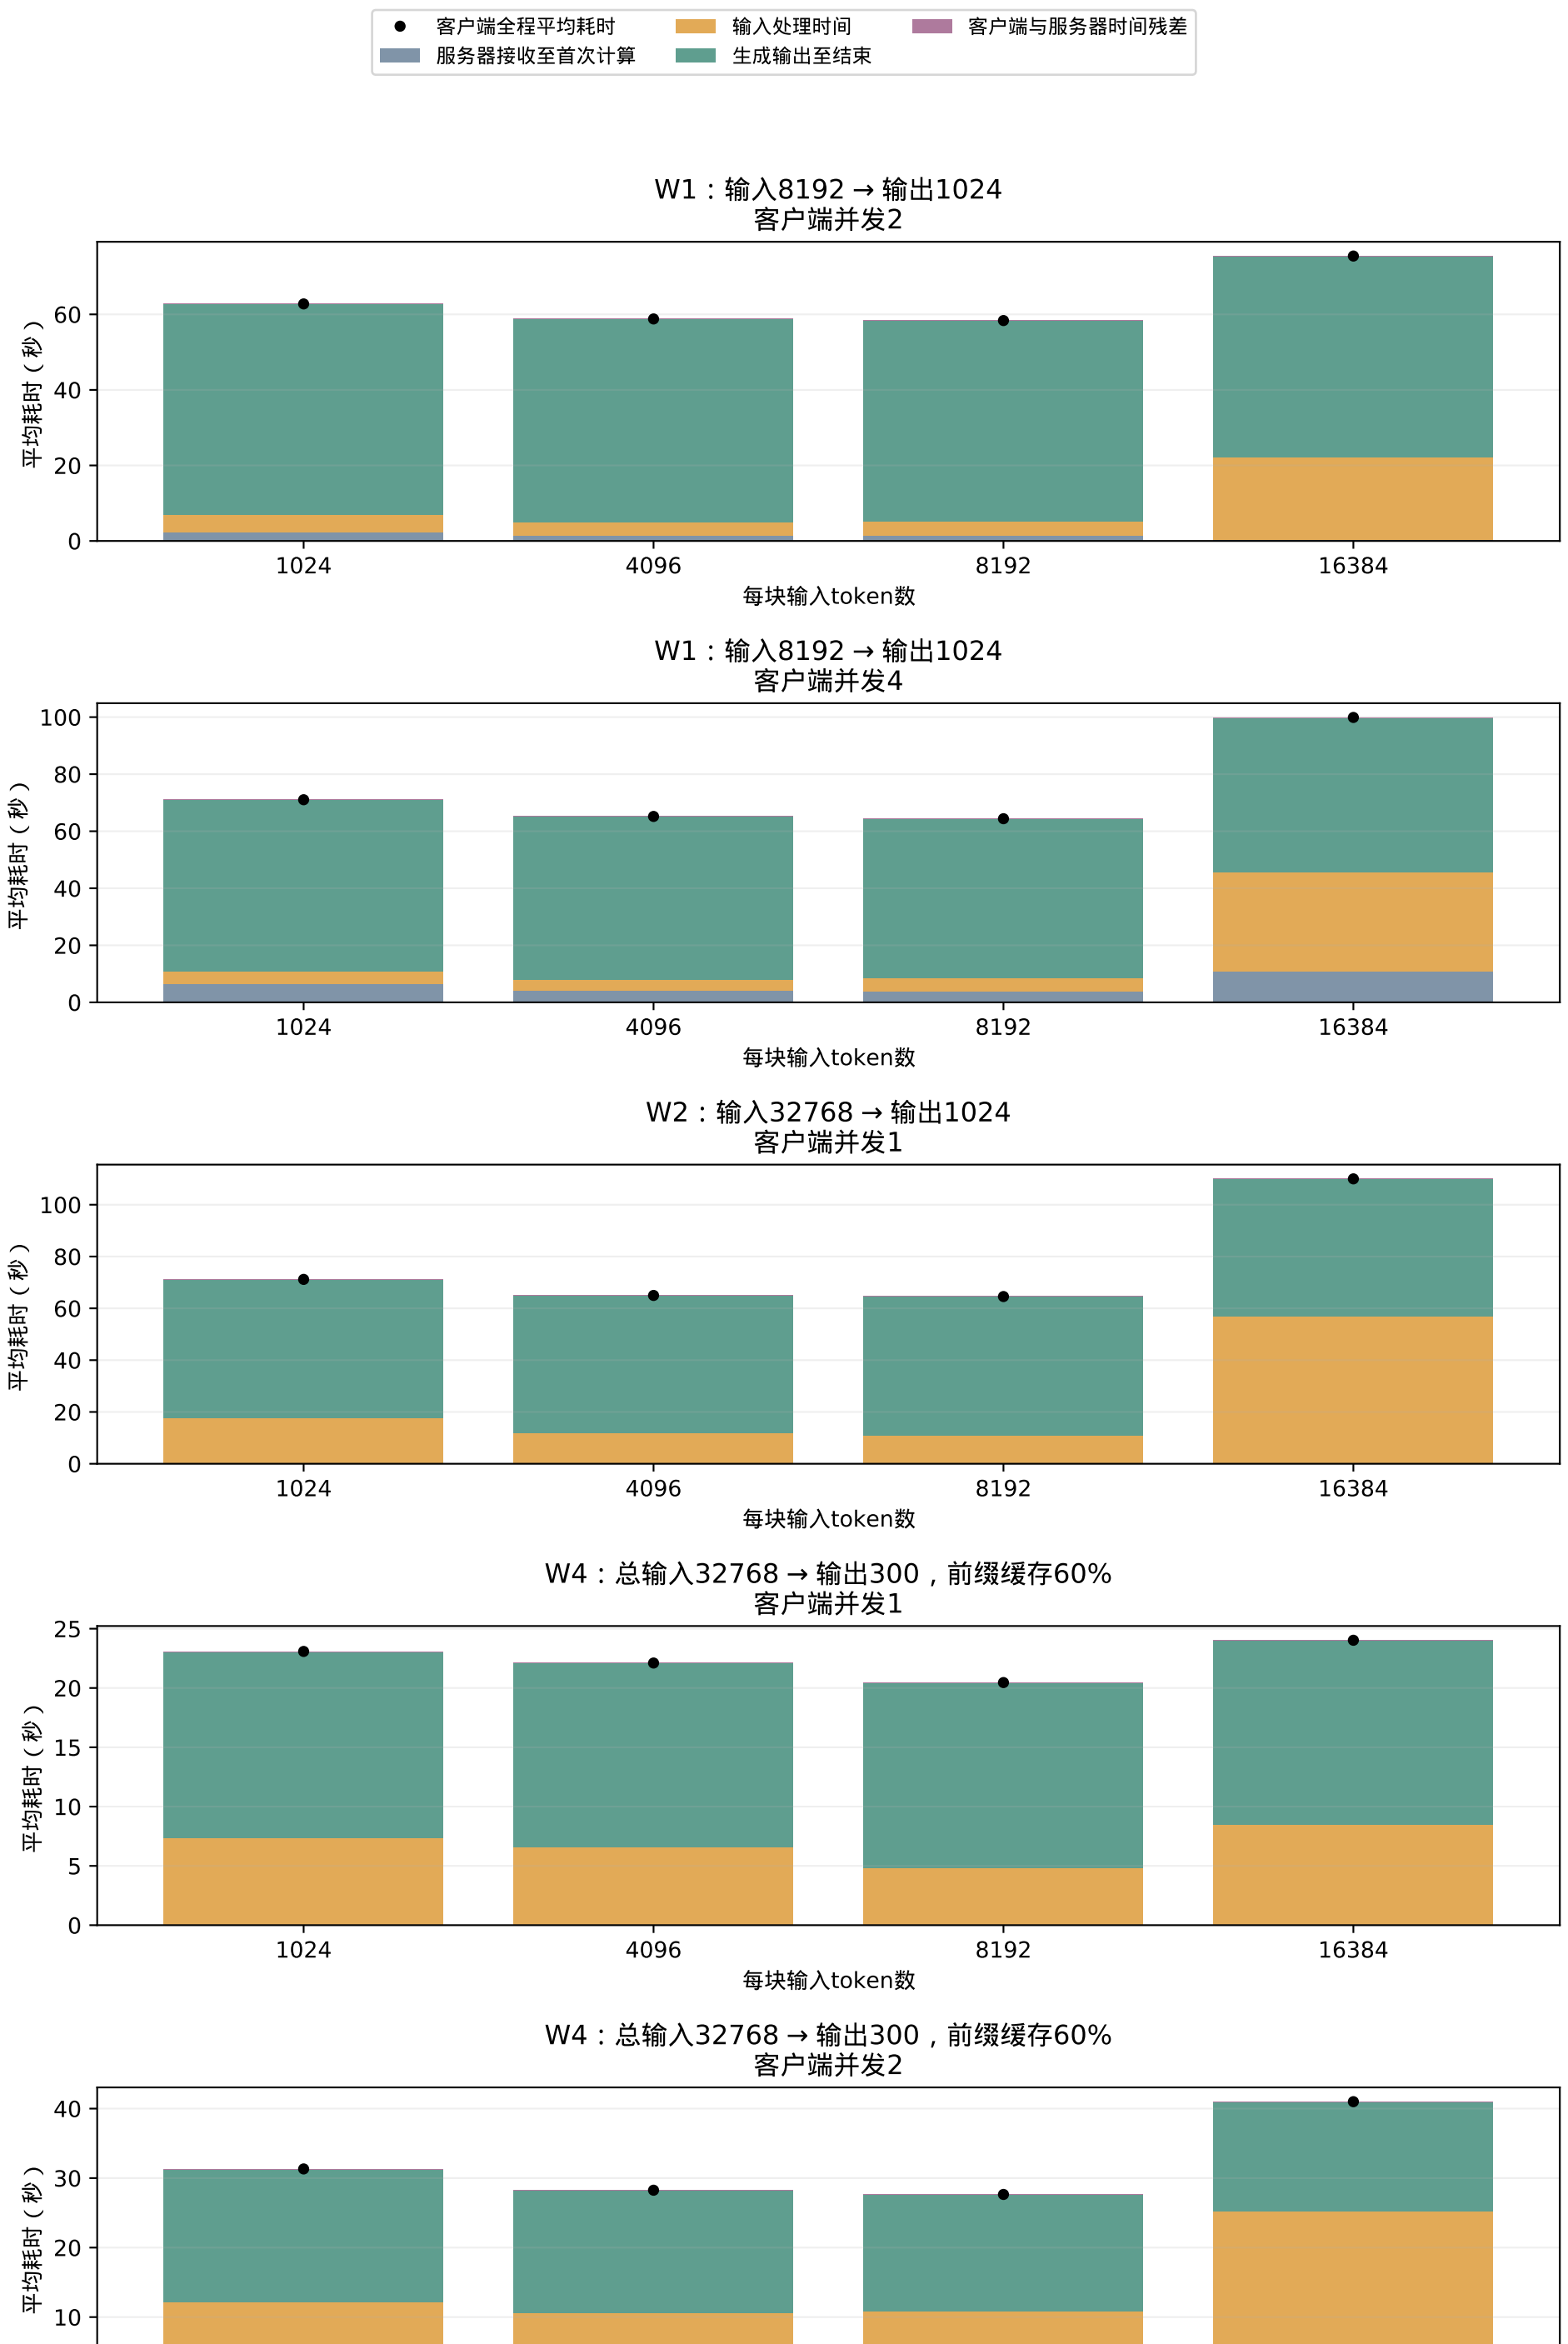
客户端全程平均耗时
输入处理时间
客户端与服务器时间残差
服务器接收至首次计算
生成输出至结束
W1：输入8192 → 输出1024
客户端并发2
平均耗时（秒）
每块输入token数
W1：输入8192 → 输出1024
客户端并发4
平均耗时（秒）
每块输入token数
W2：输入32768 → 输出1024
客户端并发1
平均耗时（秒）
每块输入token数
W4：总输入32768 → 输出300，前缀缓存60%
客户端并发1
平均耗时（秒）
每块输入token数
W4：总输入32768 → 输出300，前缀缓存60%
客户端并发2
平均耗时（秒）
每块输入token数
1024
4096
8192
16384