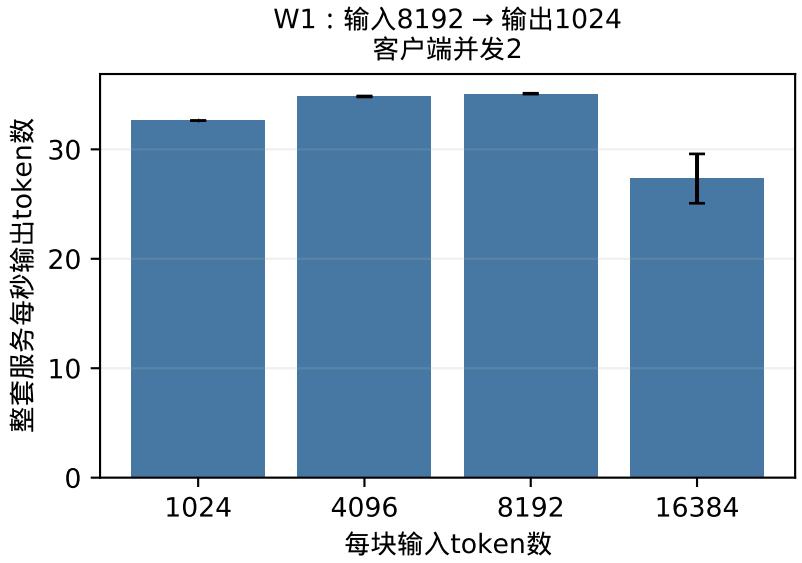
W1：输入8192 → 输出1024
客户端并发2
整套服务每秒输出token数
每块输入token数

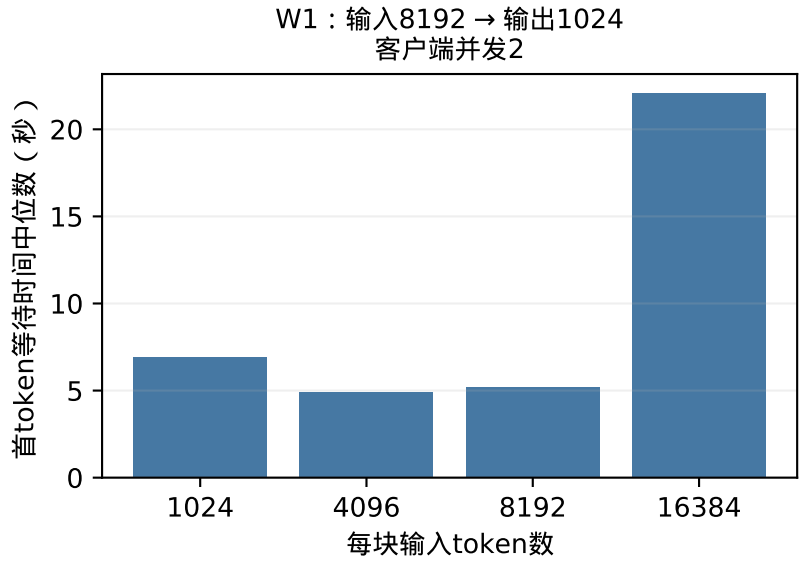
W1：输入8192 → 输出1024
客户端并发2
首token等待时间中位数（秒）
每块输入token数

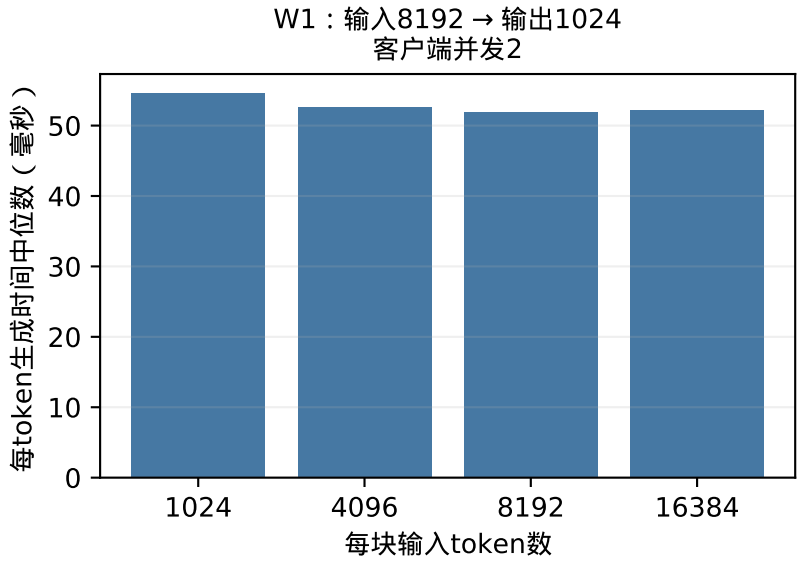
W1：输入8192 → 输出1024
客户端并发2
每token生成时间中位数（毫秒）
每块输入token数

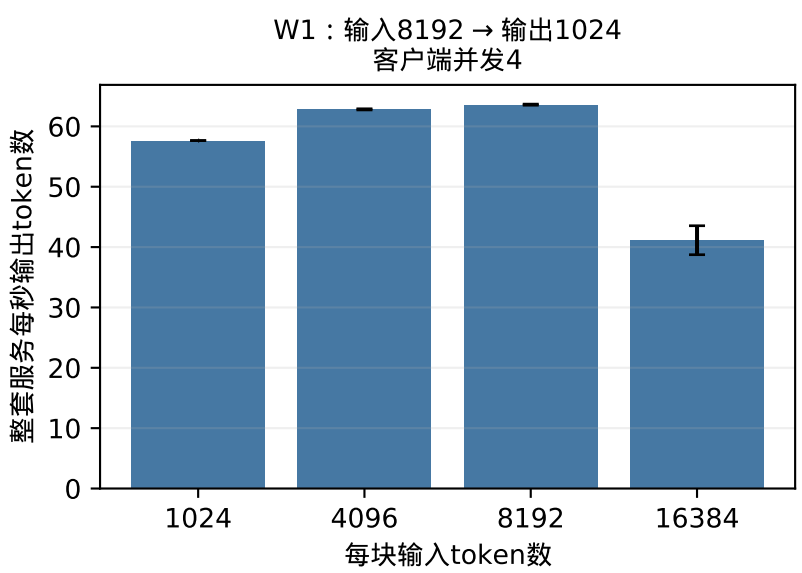
W1：输入8192 → 输出1024
客户端并发4
整套服务每秒输出token数
每块输入token数

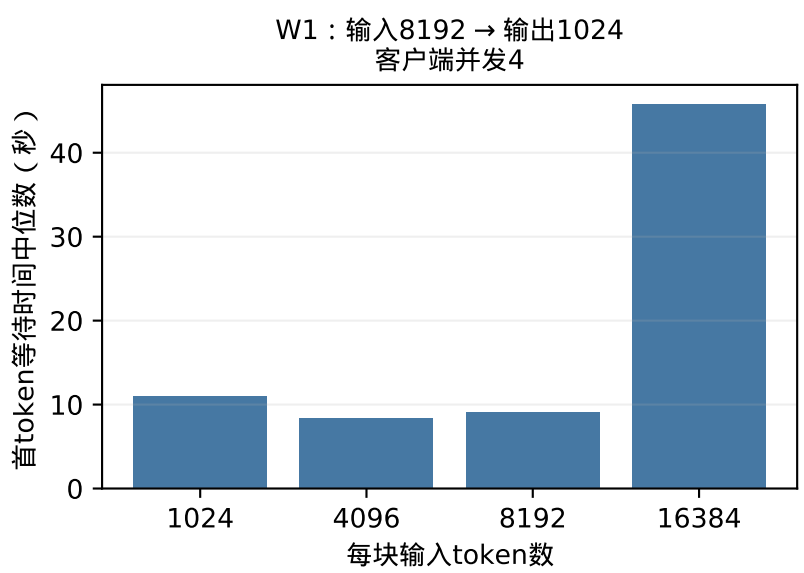
W1：输入8192 → 输出1024
客户端并发4
首token等待时间中位数（秒）
每块输入token数

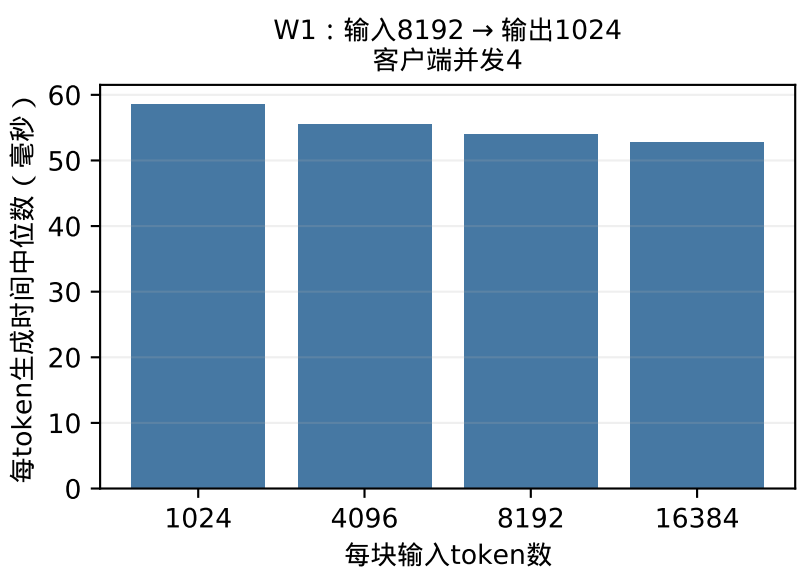
W1：输入8192 → 输出1024
客户端并发4
每token生成时间中位数（毫秒）
每块输入token数

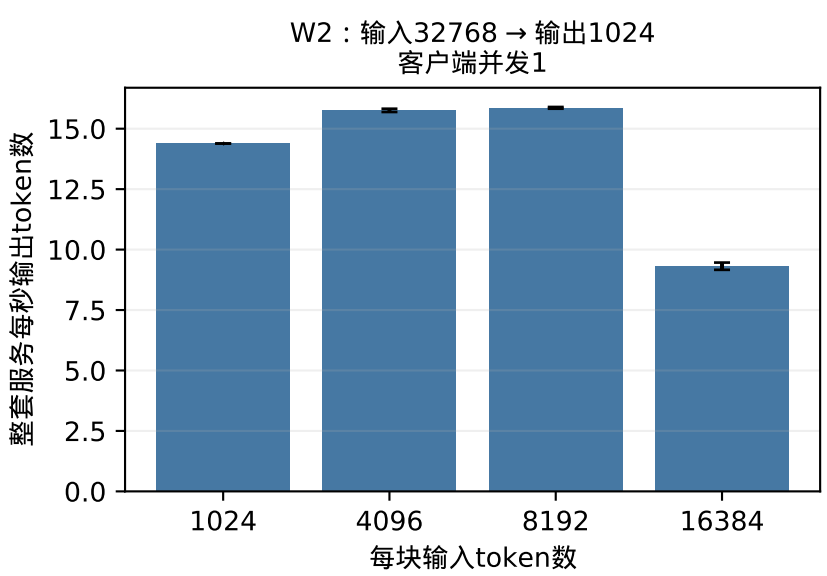
W2：输入32768 → 输出1024
客户端并发1
整套服务每秒输出token数
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发1

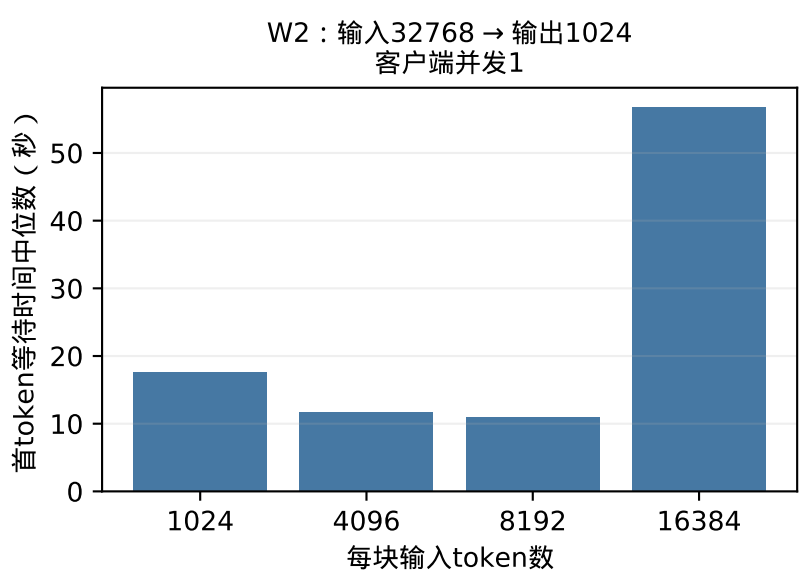
W2：输入32768 → 输出1024
客户端并发1
首token等待时间中位数（秒）
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发1

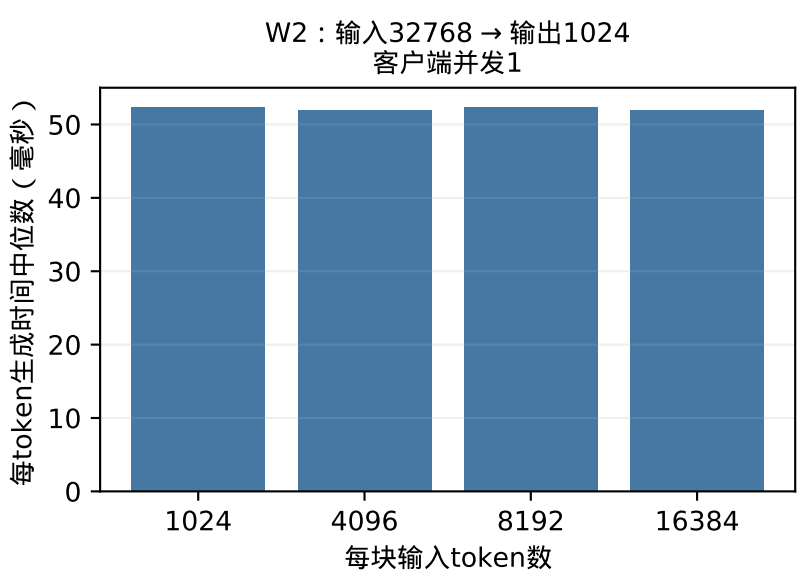
W2：输入32768 → 输出1024
客户端并发1
每token生成时间中位数（毫秒）
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发1

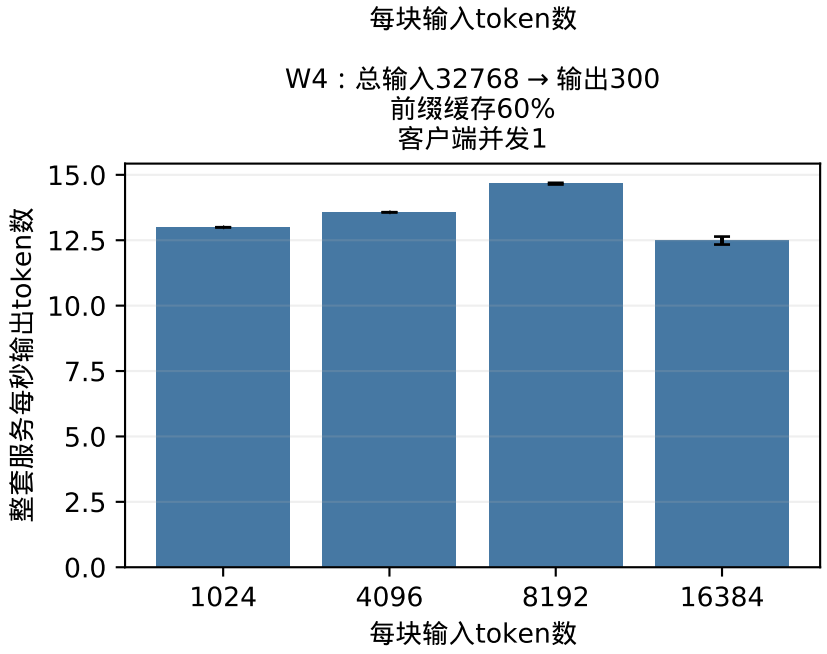
整套服务每秒输出token数
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发2

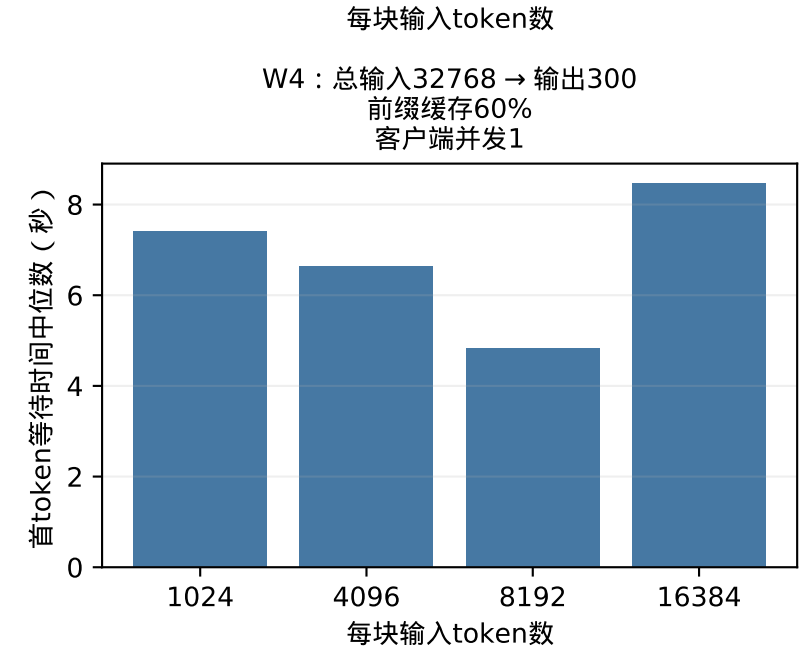
首token等待时间中位数（秒）
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发2

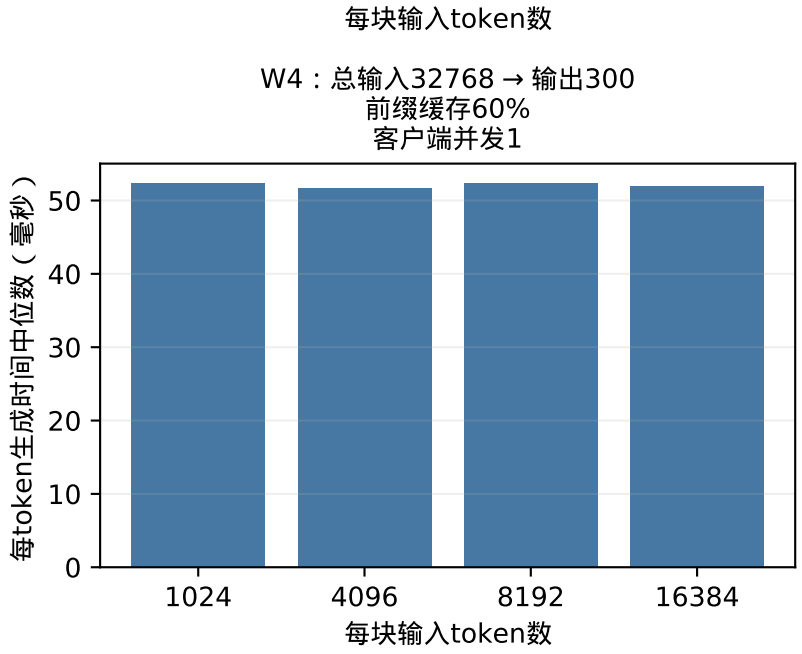
每token生成时间中位数（毫秒）
每块输入token数
W4：总输入32768 → 输出300
前缀缓存60%
客户端并发2

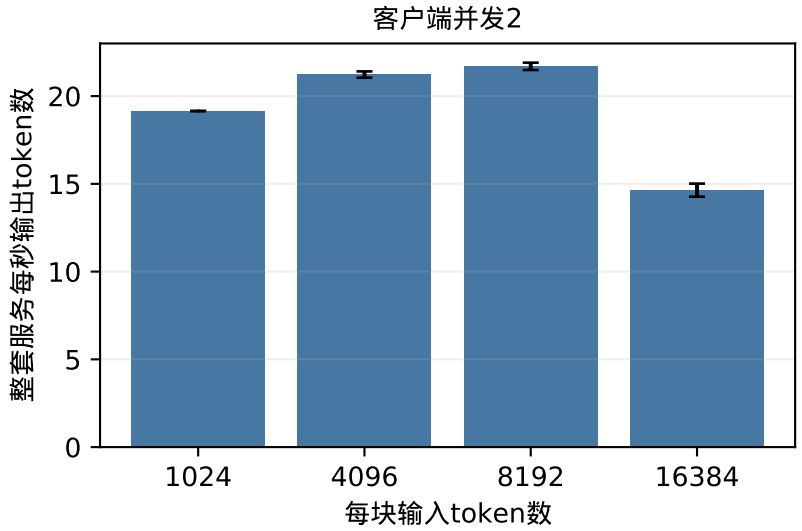
整套服务每秒输出token数
每块输入token数

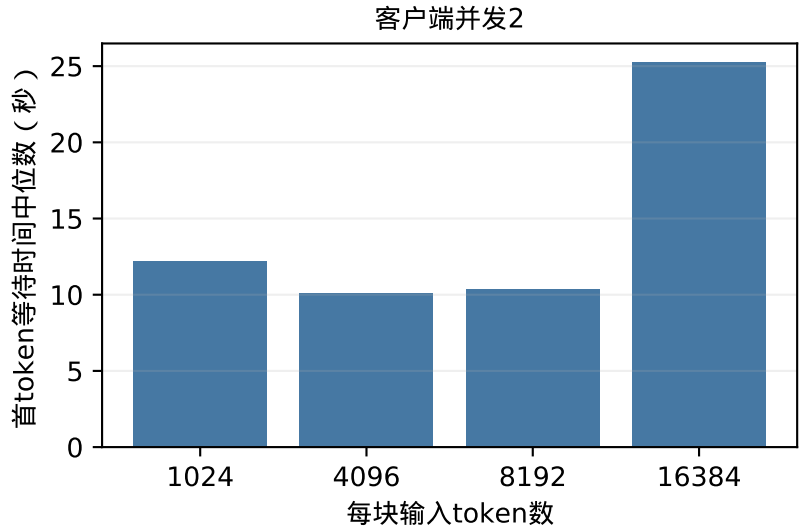
首token等待时间中位数（秒）
每块输入token数

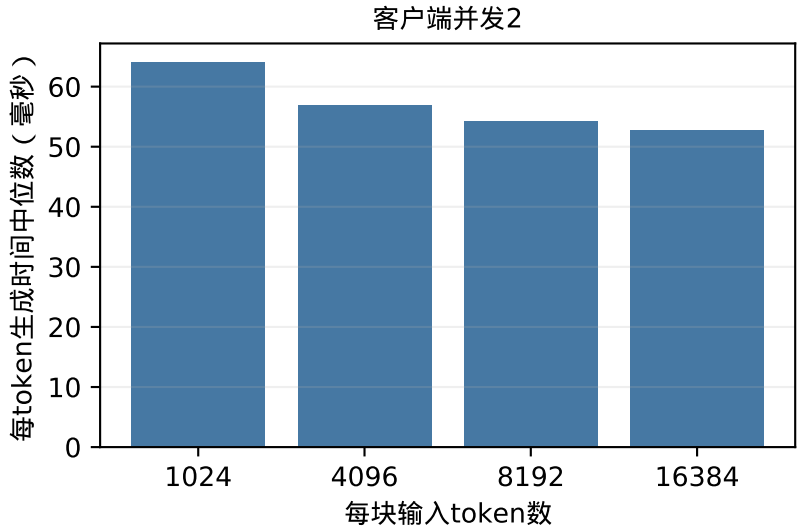
每token生成时间中位数（毫秒）
每块输入token数