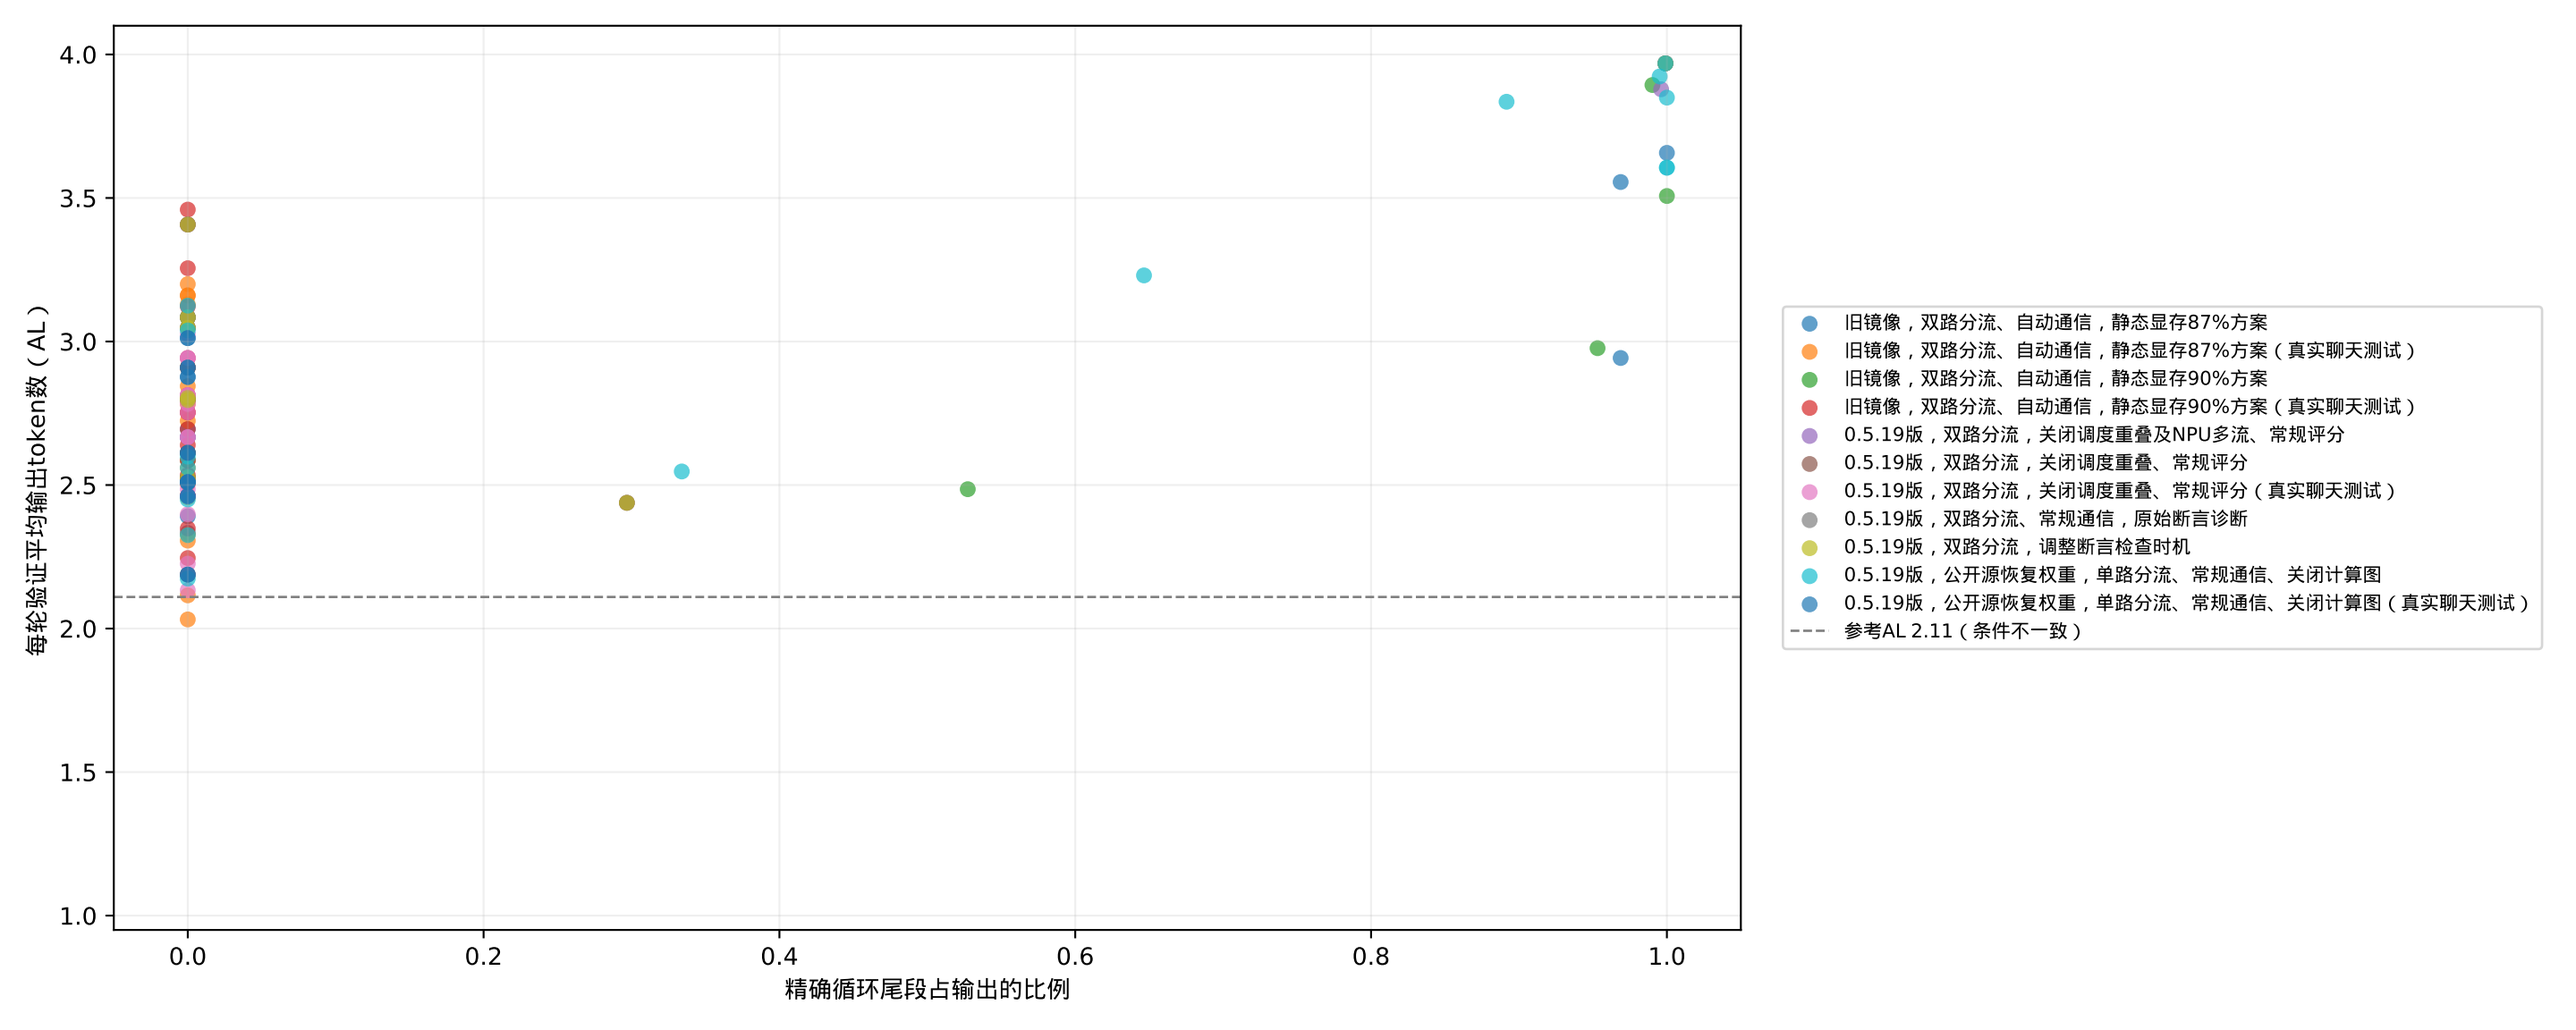

每轮验证平均输出token数（AL）
精确循环尾段占输出的比例
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.0
0.2
0.4
0.6
0.8
1.0
旧镜像，双路分流、自动通信，静态显存87%方案
旧镜像，双路分流、自动通信，静态显存87%方案（真实聊天测试）
旧镜像，双路分流、自动通信，静态显存90%方案
旧镜像，双路分流、自动通信，静态显存90%方案（真实聊天测试）
0.5.19版，双路分流，关闭调度重叠及NPU多流、常规评分
0.5.19版，双路分流，关闭调度重叠、常规评分
0.5.19版，双路分流，关闭调度重叠、常规评分（真实聊天测试）
0.5.19版，双路分流、常规通信，原始断言诊断
0.5.19版，双路分流，调整断言检查时机
0.5.19版，公开源恢复权重，单路分流、常规通信、关闭计算图
0.5.19版，公开源恢复权重，单路分流、常规通信、关闭计算图（真实聊天测试）
参考AL 2.11（条件不一致）